## Modelo de Detección de fraude Bancario

May 27, 2021

### 0.1 MODELO PARA LA DETECCION DE FRAUDE BANCARIO

• Modelo desarrollado con Deep learning para detectar casos de fraude interbancario

Los pasos a seguir son:

- Obtencion de los datos
- Preparación de datos
  - Exploración de datos
  - Transformacion de datos
- Construccion del modelo
- Evaluacion del modelo

### Ciclo del machine learning aplicado a este proyecto

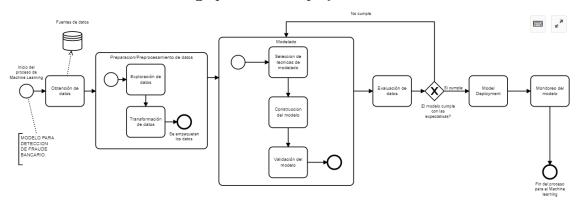


Diagrama de procesos desarrollado en BPMN

### 0.1.1 Obtencion de los datos

- Analizar las fuentes de datos
- Colecta de datos
- Integracion de las fuentes de datos

Como primer paso importamos las librerias para obtener los datos

```
[1]: from tensorflow.keras.utils import get_file
   import os

path_file=get_file(
    fname=os.path.join(os.getcwd(),"creditcard.csv"),
```

```
)
[2]: %matplotlib inline
    import pandas as pd
    import numpy as np
    import matplotlib.pyplot as plt
    import seaborn as sns; sns.set()
   Establecer una semilla (seed) para que los resultados sean reproducibles
[3]: seed=42
    np.random.seed(seed)
   Procedemos con la carga de los datos
[4]: data=pd.read_csv(path_file)
[5]:
    data.head()
[5]:
                          ۷2
                                           ۷4
                                                            ۷6
      Time
                 ۷1
                                  VЗ
                                                   ۷5
                                                                     ۷7
    0
       0.0 -1.359807 -0.072781
                             2.536347
                                     1.378155 -0.338321
                                                       0.462388
                                                               0.239599
    1
       0.0 1.191857 0.266151 0.166480 0.448154 0.060018 -0.082361 -0.078803
       1.0 -1.358354 -1.340163 1.773209
    2
                                     0.379780 -0.503198 1.800499
                                                               0.791461
       1.0 -0.966272 -0.185226 1.792993 -0.863291 -0.010309
                                                      1.247203
                                                               0.237609
       0.095921
            ٧8
                    ۷9
                               V21
                                       V22
                                                V23
                                                         V24
                                                                 V25
    0 0.098698 0.363787
                        ... -0.018307
                                   0.277838 -0.110474
                                                    0.066928
                                                             0.128539
    1 0.085102 -0.255425
                        ... -0.225775 -0.638672 0.101288 -0.339846
                                                             0.167170
    2 0.247676 -1.514654
                       ... 0.247998
                                  0.771679 0.909412 -0.689281 -0.327642
    3 0.377436 -1.387024
                       V26
                   V27
                            V28
                                Amount
                                       Class
    0 -0.189115  0.133558 -0.021053
                                149.62
    1 0.125895 -0.008983
                        0.014724
                                  2.69
                                           0
    2 -0.139097 -0.055353 -0.059752
                                378.66
                                           0
    3 -0.221929 0.062723
                                           0
                        0.061458
                                123.50
    4 0.502292
               0.219422
                       0.215153
                                 69.99
                                           0
```

origin="https://storage.googleapis.com/download.tensorflow.org/data/

## 0.1.2 Preparacion de datos

• Exploración de datos

[5 rows x 31 columns]

• Transformacion de datos ( Data wrangling, data cleaning, feature selection y feature extraction)

En esta seccion primero exploramos las informacion de los datos

## [6]: data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 284807 entries, 0 to 284806
Data columns (total 31 columns):

Dava	COLUMNIS					
#	Column	Non-Null Count Dtype				
0	Time	284807 non-null float64				
1	V1	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
2	V2	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
3	V3	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
4	V4	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
5	<b>V</b> 5	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
6	V6	284807 non-null float64				
7	V7	284807 non-null float64				
8	V8	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
9	V9	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
10	V10	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
11	V11	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
12	V12	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
13	V13	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
14	V14	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
15	V15	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
16	V16	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
17	V17	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
18	V18	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
19	V19	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
20	V20	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
21	V21	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
22	V22	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
23	V23	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
24	V24	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
25	V25	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
26	V26	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
27	V27	284807 non-null float64				
28	V28	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
29	Amount	$284807 \ \mathtt{non-null}  \mathtt{float64}$				
30	Class	284807 non-null int64				
dtypes: float64(30), int64(1)						

dtypes: float64(30), int64(1)

memory usage: 67.4 MB

Observamos los datos de float e int para la variable objetivo

• Ahora vamos a obtener los estadisticos de los datos rapidamente

# [7]: data.describe().T

[7]:		count		mean		st	d	min		25%	١
	Time	284807.0	9.48	31386e+04	47488	3.14595	5 (	0.000000	54201	500000	
	V1	284807.0	3.91	.9560e-15	:	1.95869	6 -56	3.407510	-0.	920373	
	V2	284807.0	5.68	8174e-16		1.65130	9 -72	2.715728	-0	598550	
	V3	284807.0	-8.76	9071e-15		1.51625	5 -48	3.325589	-0.	890365	
	V4	284807.0	2.78	32312e-15		1.41586	9 -5	5.683171	-0	848640	
	V5	284807.0	-1.55	2563e-15		1.38024	7 -113	3.743307	-0	691597	
	V6	284807.0	2.01	.0663e-15	:	1.33227	1 -26	5.160506	-0	768296	
	V7	284807.0	-1.69	4249e-15	:	1.23709	4 -43	3.557242	-0	554076	
	V8	284807.0	-1.92	?7028e-16		1.19435	3 -73	3.216718	-0	208630	
	V9	284807.0	-3.13	37024e-15		1.09863	2 -13	3.434066	-0	643098	
	V10	284807.0	1.76	88627e-15		1.08885	0 -24	1.588262	-0	535426	
	V11	284807.0	9.17	70318e-16		1.02071	3 -4	1.797473	-0	762494	
	V12	284807.0	-1.81	.0658e-15	(	0.99920	1 -18	3.683715	-0	405571	
	V13	284807.0	1.69	3438e-15	(	0.99527	4 -5	5.791881	-0	648539	
	V14	284807.0	1.47	′9045e-15	(	0.95859	6 -19	9.214325	-0	425574	
	V15	284807.0	3.48	32336e-15	(	0.91531	6 -4	1.498945	-0	582884	
	V16	284807.0	1.39	2007e-15	(	0.87625	3 -14	1.129855	-0	468037	
	V17	284807.0	-7.52	28491e-16	(	0.84933	7 -25	5.162799	-0	.483748	
	V18	284807.0	4.32	28772e-16	(	0.83817	6 -9	9.498746	-0	498850	
	V19	284807.0	9.04	9732e-16	(	0.81404		7.213527	-0	456299	
	V20	284807.0	5.08	85503e-16	(	0.77092	5 -54	1.497720	-0	211721	
	V21	284807.0		37294e-16	(	0.73452		1.830382	-0	228395	
	V22	284807.0		9909e-16		0.72570		0.933144	-0	542350	
	V23	284807.0	5.36	7590e-16	(	0.62446	0 -44	1.807735	-0	161846	
	V24	284807.0	4.45	8112e-15	(	0.60564	7 -2	2.836627	-0	354586	
	V25	284807.0		3003e-15		0.52127		0.295397		317145	
	V26	284807.0		9104e-15		0.48222		2.604551		.326984	
	V27	284807.0	-3.66	0161e-16		0.40363		2.565679		.070840	
	V28	284807.0				0.33008		5.430084		.052960	
	Amount	284807.0		34962e+01		0.12010		0.000000		600000	
	Class	284807.0	1.72	?7486e-03	(	0.04152	7 (	0.000000	0	.000000	
			E09/		7-0/						
	Time	84692.000	50%	139320.500	75%	172792	ma				
	V1	0.018		1.31			.45493				
	V1 V2	0.016		0.803			.05772				
	V2 V3	0.003		1.02			.3825				
	V3 V4	-0.019		0.743			.87534				
	V4 V5	-0.019		0.743			.80166				
	V6	-0.054		0.81			.30162				
	V6 V7	0.040		0.570			.58949				
	V 7	0.040		0.37			.00720				
	V9	-0.051		0.52			.59499				
	V3 V10	-0.031		0.35			.74513				
	A T O	-0.092	.J11	0.450	J323	23	.14013	00			

V11	-0.032757	0.739593	12.018913
V12	0.140033	0.618238	7.848392
V13	-0.013568	0.662505	7.126883
V14	0.050601	0.493150	10.526766
V15	0.048072	0.648821	8.877742
V16	0.066413	0.523296	17.315112
V17	-0.065676	0.399675	9.253526
V18	-0.003636	0.500807	5.041069
V19	0.003735	0.458949	5.591971
V20	-0.062481	0.133041	39.420904
V21	-0.029450	0.186377	27.202839
V22	0.006782	0.528554	10.503090
V23	-0.011193	0.147642	22.528412
V24	0.040976	0.439527	4.584549
V25	0.016594	0.350716	7.519589
V26	-0.052139	0.240952	3.517346
V27	0.001342	0.091045	31.612198
V28	0.011244	0.078280	33.847808
Amount	22.000000	77.165000	25691.160000
Class	0.000000	0.000000	1.000000

Verificamos la presencia de datos nulos en los datos

## [8]: data.isnull().sum(axis=0)

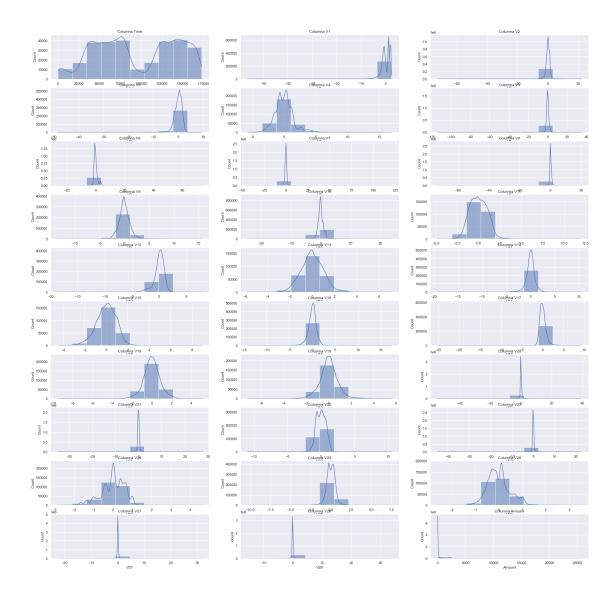
```
V23
           0
V24
           0
V25
           0
V26
           0
V27
           0
V28
           0
Amount
           0
Class
           0
dtype: int64
```

Por cierto **no hay precencia de datos nulos** en dichos datos, entonces vamos a observar su comportamiento

- La columna tiempo no guarda informacion significativa por lo cual la excluiremos del analisis
- Observamos la distribucion de los datos en base a un histograna

```
[9]: fig,axes=plt.subplots(10,3,sharex=False,figsize=(30,30))
    columns_tabla=data.columns

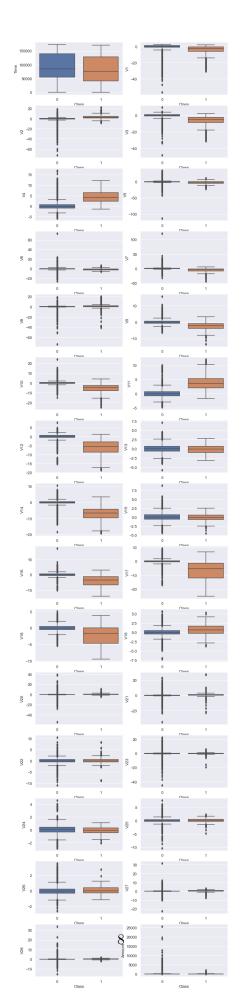
for i, ax in enumerate(axes.flat):
        sns.histplot(data.iloc[:,i],bins=10,kde=True,ax=ax)
        ax.set_title(f"Columna {columns_tabla[i]}")
    plt.show()
```



• Observamos las anomalias de los datos. excluyendo la variable dependiente que pertenece a la columna

```
[10]: fig,axes=plt.subplots(15,2,figsize=(10,50))
columns_tabla=data.columns

for i,ax in enumerate(axes.flat):
    sns.boxplot(x="Class",y=columns_tabla[i],data=data,ax=ax)
```



La mayoria de los datos posee anomalias pero en estos casos sabemos que no son malas debido a que tambien corresponden a los casos donde hubo fraude.

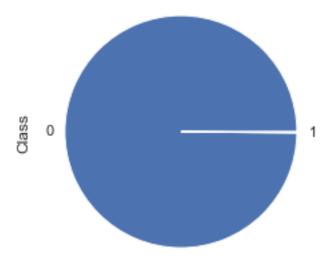
Debemos analizar mas detenidamiente estas muestras de anomalias

• Observamos la distribución de las clases de los datos a taves de todos el set de información

```
[11]: conteo=data.Class.value_counts(normalize=True)
    display(conteo.map(lambda x: f"{x*100:0.2f}%"))
    plt.rcParams["figure.figsize"]=(4,4)
    conteo.plot(kind="pie",)

0 99.83%
1 0.17%
    Name: Class, dtype: object

[11]: <AxesSubplot:ylabel='Class'>
```



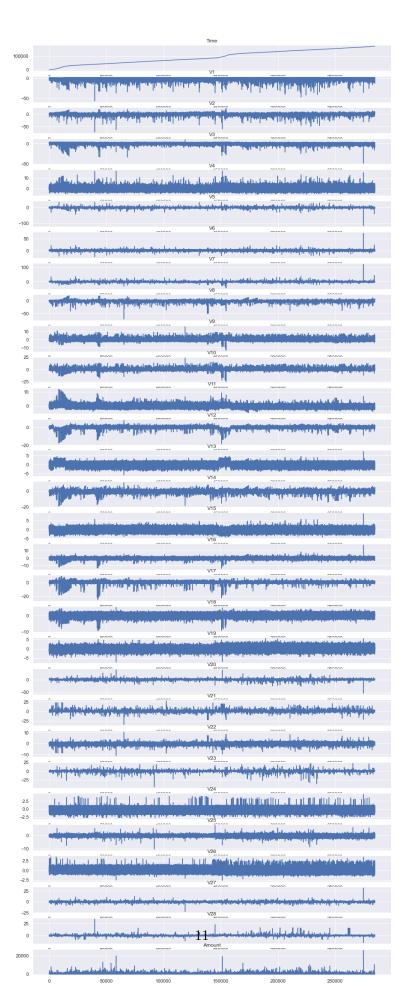
Tenemos como clase mayoritaria dominante los casos que no fueron fraude financiero con un 99.83% del total de datos, mientras que la minoria se corresponde con lo que queremos obtener (0.17%).

Este es un verdadero problema de desbalanceamiento de clases.Debido que el modelo aprendera mas de los datos de la clase mayoritaria que la de la clase minoritaria correspondiente a los fraude detectados.

• Observamos las tendencias de los datos

```
fig,axes=plt.subplots(30,1,figsize=(15,40))

for i , ax in enumerate(axes.flat):
    ax.plot(data.iloc[:,i])
    ax.set_title(data.columns[i])
plt.show()
```



```
[13]: plt.rcParams["figure.figsize"] = plt.rcParamsDefault["figure.figsize"] ⊔

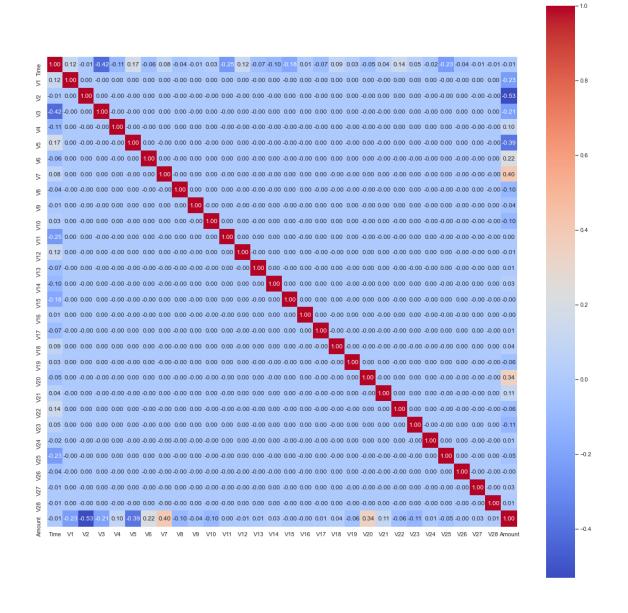
→#reseteamos la configuracion del tamaño del grafico
```

• Analizamos la correlacion de las variables. Esto es muy importante para evitar la colinealidad en los datos

```
[14]: corr=data.iloc[:,:-1].corr(method="pearson")

plt.figure(figsize=(20,20))
sns.heatmap(corr.T,fmt="0.2f",annot=True,square=True,cmap="coolwarm")
```

[14]: <AxesSubplot:>



Buscamos la **colinealidad** entre las variables, esto se da cuando dos variables estan correlacionadas entre si. Por otro lado tambien podemos encontrar la **Multicolinealidad** cuando mas de una variable indepediente se encuentra correlacionada

Las correlaciones encontradas fueron las siguientes:

• V1 y Amount estan levemente correlacionadas con un coeficiente de correlacion de -0.23. Esto es una correlacion inversa que significa que el aumento de una tiene una disminucion en el valor del otro par.

```
[15]: from scipy.stats import pearsonr
```

Creamos una funcion que calcule la correlacion entre dos variables y nos entregue a traves de un nivel de significancia si la correlacion es estadisticamente significativa

```
def test_correlation(X1,X2,alpha=0.05):
    corr,p_valor=pearsonr(X1,X2) #comprobamos la correlacion entre X1 y X2
    #Utilizamos el p_valor para determinar si el coeficiente de correlacion es⊔
    →estadisticamente significativo
    #si el p_valor (alfa) es menor o igual al nivel de significacia 0.05⊔
    →entonces la correlaciones estadisiticamente significativa.

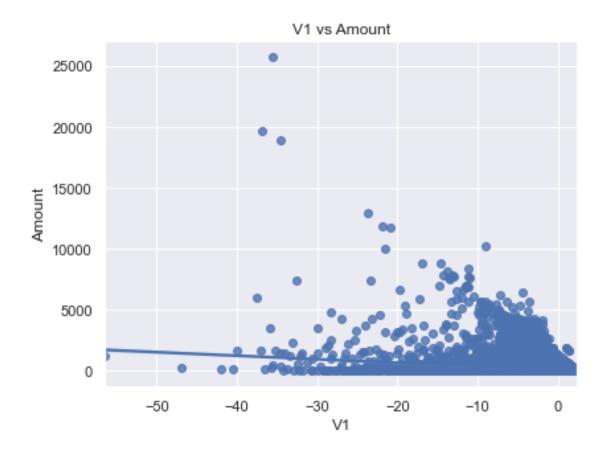
print(f"COEF. correlacion: {corr} | p-valor : {p_valor}")
    print("La correlacion es estadisticamente significativa" if p_valor<=alpha⊔
    →else "La correlacion NO es significativa")
```

```
[17]: #ejecutamos el test de correlacion test_correlation(data.V1,data.Amount)
```

COEF. correlacion: -0.2277086529224042 | p-valor: 0.0 La correlacion es estadisticamente significativa

```
[18]: sns.regplot(x="V1",y="Amount",data=data)
plt.title("V1 vs Amount")
```

[18]: Text(0.5, 1.0, 'V1 vs Amount')



Concluimos que V1 y Amount tienen una correlacion estadisticamente significativa

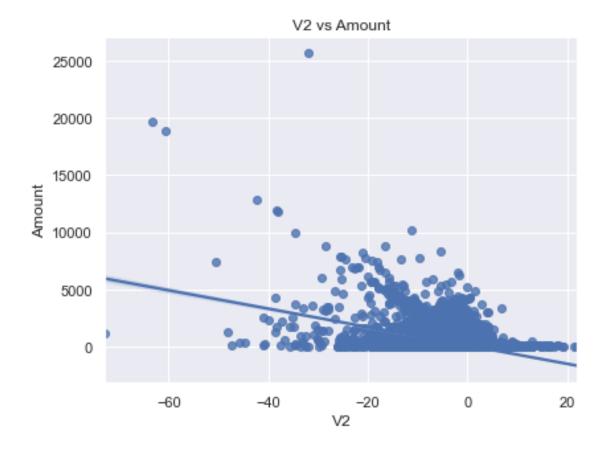
 $\bullet$  V2 y Amount estan moderadamente correlacionadas con un coeficiente de correlacion negativa de -0.53. Por lo cual tambien demostramos que estan significativamente correlacionados

```
[19]: test_correlation(data.V2,data.Amount)

COEF. correlacion: -0.5314089393280333  | p-valor : 0.0
La correlacion es estadisticamente significativa

[20]: sns.regplot(x="V2",y="Amount",data=data)
    plt.title("V2 vs Amount")

[20]: Text(0.5, 1.0, 'V2 vs Amount')
```



- Tenemos la correlacion entre las variable independiente V3 con Time (-0.42) y Amount (-0.21)
- Descartamos la variable Time de este analisis debido a que el tiempo desde ya no aporta al modelo y sera exluido mas adelante

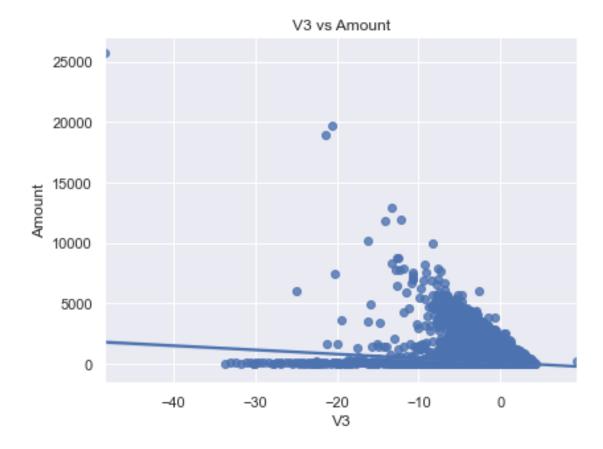
Por lo tanto probamos la correlacion entre  ${\bf V3}$  y  ${\bf Amount}$  y concluimos tambien que tienen una correlacion significativa

```
[21]: test_correlation(data.V3,data.Amount)

COEF. correlacion: -0.21088047528990986  | p-valor : 0.0
    La correlacion es estadisticamente significativa

[22]: sns.regplot(x="V3",y="Amount",data=data)
    plt.title("V3 vs Amount")
```

[22]: Text(0.5, 1.0, 'V3 vs Amount')



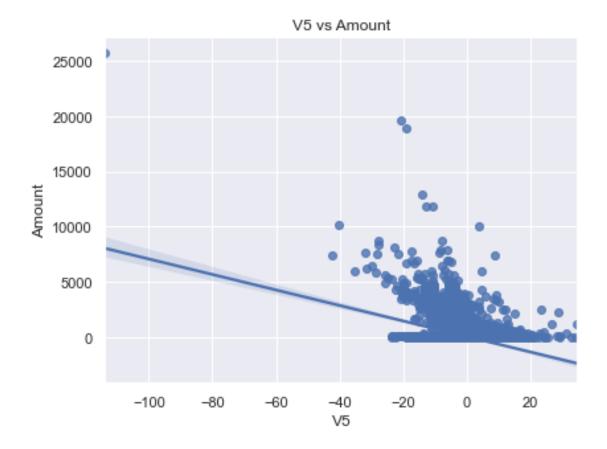
- ullet La  ${f V4}$  no se encuentra muy correlacionada con las demas variables, esta variable puede ser buena
- $\bullet$  La V5 se encuentra correlacionada con Amount

```
[23]: test_correlation(data.V5,data.Amount)
```

COEF. correlacion: -0.38635625616306024 | p-valor : 0.0 La correlacion es estadisticamente significativa

```
[24]: sns.regplot(x="V5",y="Amount",data=data)
plt.title("V5 vs Amount")
```

[24]: Text(0.5, 1.0, 'V5 vs Amount')



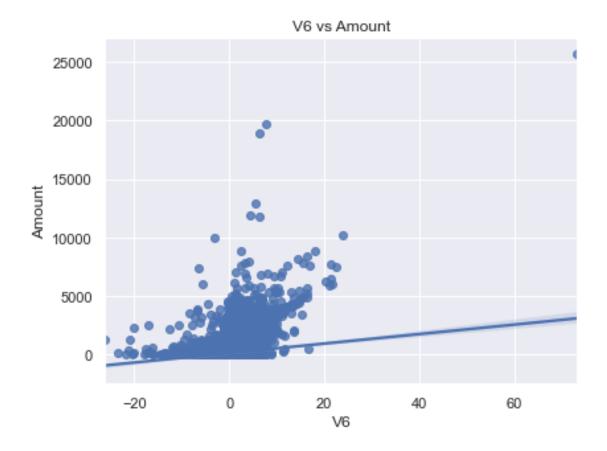
ullet La V6 se encuentra correlacionada con Amount

```
[25]: test_correlation(data.V6,data.Amount)
```

COEF. correlacion: 0.2159811802252792  $\mid$  p-valor : 0.0 La correlacion es estadisticamente significativa

```
[26]: sns.regplot(x="V6",y="Amount",data=data)
plt.title("V6 vs Amount")
```

[26]: Text(0.5, 1.0, 'V6 vs Amount')



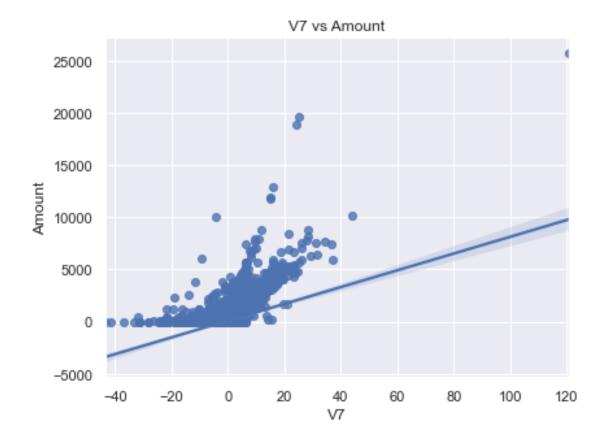
- La V7 se encuentra correlacionada con Amount

```
[27]: test_correlation(data.V7,data.Amount)
```

COEF. correlacion: 0.39731127818168943 | p-valor : 0.0 La correlacion es estadisticamente significativa

```
[28]: sns.regplot(x="V7",y="Amount",data=data)
plt.title("V7 vs Amount")
```

[28]: Text(0.5, 1.0, 'V7 vs Amount')



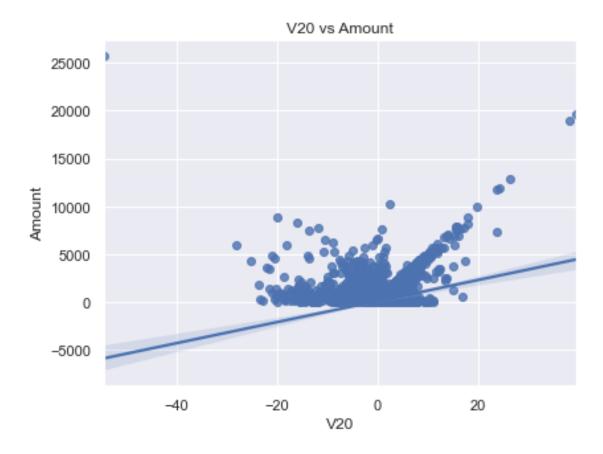
- Por ultimo tambien notamos una correlacion significativa entre  ${\bf V20}$  y  ${\bf Amount}$ 

```
[29]: test_correlation(data. V20, data. Amount)
```

COEF. correlacion:  $0.33940340454617346 \mid p-valor: 0.0$  La correlacion es estadisticamente significativa

```
[30]: sns.regplot(x="V20",y="Amount",data=data)
plt.title("V20 vs Amount")
```

[30]: Text(0.5, 1.0, 'V20 vs Amount')



• El resto de variables se excluyeron de este analisis debido a que en la matriz de correlacion no tuvieron coeficientes de correlacion muy buenos con respecto a otras variables

Ahora realizaremos analisis orientados a una preparacion de datos

[31]: #analizamos el rango de cada variable en el dataset esto es para ver sus∟

⇒limites y poder realizar un escalamiento de datos mas adelanta

data.aggregate([np.min,np.max]).T

[31]:		amin	amax
	Time	0.000000	172792.000000
	V1	-56.407510	2.454930
	V2	-72.715728	22.057729
	V3	-48.325589	9.382558
	V4	-5.683171	16.875344
	<b>V</b> 5	-113.743307	34.801666
	V6	-26.160506	73.301626
	V7	-43.557242	120.589494
	V8	-73.216718	20.007208
	<b>V</b> 9	-13.434066	15.594995
	V10	-24.588262	23.745136

-4.797473	12.018913
-18.683715	7.848392
-5.791881	7.126883
-19.214325	10.526766
-4.498945	8.877742
-14.129855	17.315112
-25.162799	9.253526
-9.498746	5.041069
-7.213527	5.591971
-54.497720	39.420904
-34.830382	27.202839
-10.933144	10.503090
-44.807735	22.528412
-2.836627	4.584549
-10.295397	7.519589
-2.604551	3.517346
-22.565679	31.612198
-15.430084	33.847808
0.000000	25691.160000
0.000000	1.000000
	-18.683715 -5.791881 -19.214325 -4.498945 -14.129855 -25.162799 -9.498746 -7.213527 -54.497720 -34.830382 -10.933144 -44.807735 -2.836627 -10.295397 -2.604551 -22.565679 -15.430084 0.000000

Podemos observar que el rango de datos se encuentra muy disperso como tambien existen columnas como **Time** y **Amount** que poseen rango mas anchos debido a los dato que manejan. Esto amerita que luego que los datos esten preparados se escalen los datos para que posean un rango comun

• Podemos esforzarnos y buscar **outliers** pero en este contexto de fraude bancario a aveces las anomalias en casos de fraude son las que nuestro modelo debe predecir para ajustarnos correctamente a los datos. Ahora tambien con respecto a los casos de no fraude, es normal que los clientes retiren cantidades infimas y luego cantidades grandes despues de un periodo largo de tiempo. En este contexto penalizar los outliers no es una buena idea.

Ahora examinemos otro problema comun en los datos. Los valores duplicados.

```
[32]: mask_duplicated=data.duplicated(subset=None) #devuelve la cantidad de valores⊔

→duplicados en funcion de todas las columnas

print(mask_duplicated.sum())
```

1081

Como parte de nuestro analisis podemos saber cuales son esas filas duplicadas, para ellos hacemos uso de la matriz booleana de enmascaramiento devuelta como resultado

```
data[mask_duplicated].head() #mostramos los 5 primeras filas
[33]:
                                                        ۷4
           Time
                                   V2
                                             V3
                                                                   ۷5
                                                                             ۷6
      33
           26.0 -0.529912
                            0.873892
                                       1.347247
                                                  0.145457
                                                            0.414209
                                                                       0.100223
      35
           26.0 -0.535388
                            0.865268
                                       1.351076
                                                  0.147575
                                                            0.433680
                                                                       0.086983
```

```
۷7
                     87
                               ۷9
                                           V21
                                                     V22
                                                               V23 \
33
    0.711206
              0.176066 -0.286717
                                      0.046949
                                                0.208105 -0.185548
                                      0.049526
35
    0.693039
               0.179742 -0.285642
                                                0.206537 -0.187108
113 -0.036715 0.350995 0.118950
                                      0.102520
                                                0.605089
                                                          0.023092
114 -0.036715
              0.350995
                        0.118950
                                      0.102520
                                                0.605089
                                                          0.023092
                                                0.605089
115 -0.036715
              0.350995 0.118950
                                      0.102520
                                                          0.023092
          V24
                    V25
                              V26
                                        V27
                                                               Class
                                                  V28
                                                       Amount
     0.001031
              0.098816 -0.552904 -0.073288
                                             0.023307
                                                         6.14
33
                                                                   0
               0.098117 -0.553471 -0.078306
35
                                                         1.77
     0.000753
                                             0.025427
                                                                   0
113 -0.626463
              0.479120 -0.166937
                                  0.081247
                                             0.001192
                                                         1.18
                                                                   0
114 -0.626463
              0.479120 -0.166937
                                   0.081247
                                             0.001192
                                                         1.18
                                                                   0
115 -0.626463  0.479120 -0.166937  0.081247
                                             0.001192
                                                         1.18
                                                                   0
```

[5 rows x 31 columns]

• Es sorprendente saber de la existencia de **1081 datos duplicados**. Estos se eliminaran en la fase de procesamiento de datos

Ahora veamos la distribucion de de clases contenidas en dichos datos duplicados

```
[34]: data[mask_duplicated].Class.value_counts()
```

```
[34]: 0 1062
1 19
```

Name: Class, dtype: int64

Ahora bien, puede que estas transacciones no vengan de un mismo cliente y que sea casualidad que tengan las mismas características, como tambien de que hubiera una fuga en la base de datos y se duplicaron algunas transacciones a la misma hora. En ambos casos se debe retirar del conjunto de datos mas adelante

```
[56]: #observamos la dispersion de los datos a traves del analisis de componentes

principales
from sklearn.decomposition import PCA

#creo una funcion para mostrar la dispersion de clases por cada dataset

def plot_scatter_by_class(ax=None,data=None):
    pca=PCA(n_components=2)
    XY=pca.fit_transform(data.iloc[:,1:-1]) #excluimos el Time y la columna

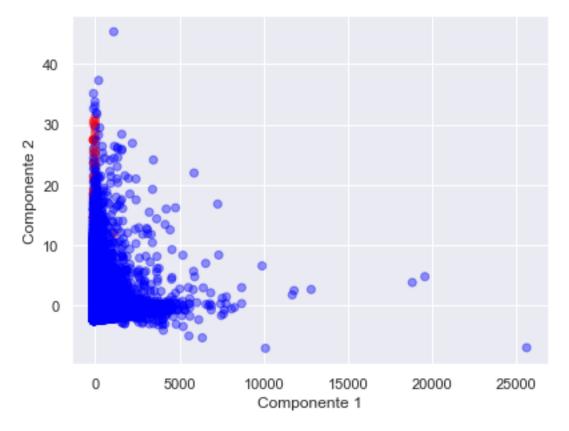
Class

color_map=np.array(["blue","red"])[data.Class] #Los No fraudes son Azules,y

fraudes rojos
    if ax is None:
    __,(ax)=plt.subplots(1,1)
```

```
ax.scatter(XY[:,0],XY[:,1],color=color_map,alpha=0.4)
ax.set_ylabel("Componente 2")
ax.set_xlabel("Componente 1")

plot_scatter_by_class(data=data)
```



### Otros pasos

Las caracteristicas de entrada son continuas y la salida es categorica. Por lo tanto no necesitamos realizar algun procesamiento adicional de condificación en caliente u ordinales

### 0.1.3 PROCESAMIENTO DE DATOS

• Ya estamos listos para aplicar tecnicas de procesamiento de datos.

En primer lugar desde un inicio notamos que la columna tiempo no aporta valor, ya que solo apunta a la hora donde se realizo dicha transaccion.

```
[44]: df_cleaned=data.copy() #los datos de analisis los copiamos al dataframe de⊔
→ limpeza para empezar con el proceso
```

[45]: 1081

```
[46]: df_cleaned=df_cleaned.drop_duplicates(subset=None) #borramos los duplicados
```

```
[47]: df_cleaned.drop("Time",axis=1,inplace=True) #borramos la columna tiempo. No⊔
→aportaba al modelo
```

Las variables V1,V2,V3,V5,V6,V7 ... V20. Estaba correlacionadas con Amount pero no a un alto nivel mayor a 0.70, debido a que es normal que las caracteristicas flutuen generando un poco de correlacion, no podemos eliminarlas por ser colineales porque su coeficiente no era muy elevado como para eliminar una y dejar otra, cada quien tenia sus particularidades.

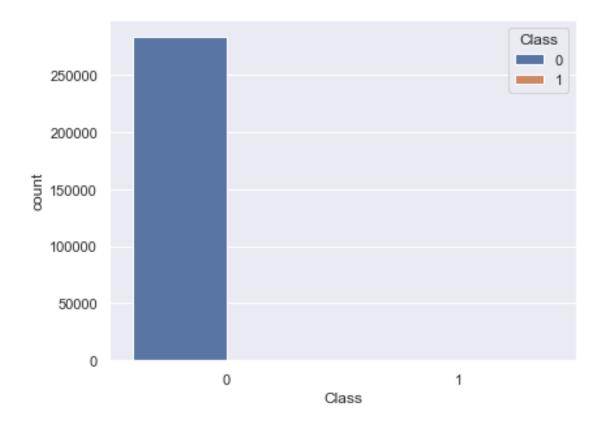
Estas variables no se eliminan en esta fase (\*)

(\*) Si el modelo no tiene mejoras podemos regresar a la fase de exploracion y analisis para considerar eliminar dichas variables. El proceso de machine learning es iterativo

El problema de datos desbalanceados (99+% No fraude | 1% Si Fraude) Tener datos desbalanceados hace sesgar los resultados del modelo, debido a que se familiarizara mas con la clase mayoritaria que acabara prediciendo muy buenos datos sobre esta, que en lugar de la clase minoritaria.

A continuación tenemos la proporción actual

```
[48]: print("====Conteo de Clases====")
      display(df cleaned.Class.value counts())
      print("====Proporcion de clases====")
      display(df_cleaned.Class.value_counts(normalize=True).map(lambda x: f"{x:0.
       →10f}%"))
     ====Conteo de Clases====
     0
          283253
     1
             473
     Name: Class, dtype: int64
     ====Proporcion de clases====
          0.9983328986%
     0
          0.0016671014%
     Name: Class, dtype: object
[49]: ax=sns.countplot(x="Class", hue="Class", data=df cleaned)
```



**Primer camino: Submuestreo** Esta es una tecnica para reducir la proporcion de la clase mayoritaria para que este al nivel de la minoritaria, tal que al final el proceso, los datos se reducen al nivel de esta ultima.

```
[50]: #Nuestro conjunto de datos estaba desequilibrado con el 99% de clase negativa y

→1% positiva en fraude.

#En este caso tenemos que hacer un submuestreo en favor a la clase

→minoritaria(nuestro objetivo), para que se equilibren los datos y el modelo

→no nos arroje metricas sesgadas

from imblearn.under_sampling import RandomUnderSampler

undersampling=RandomUnderSampler(random_state=42)

X_sample,y_sample=undersampling.fit_resample(df_cleaned.iloc[:,:-1],df_cleaned.

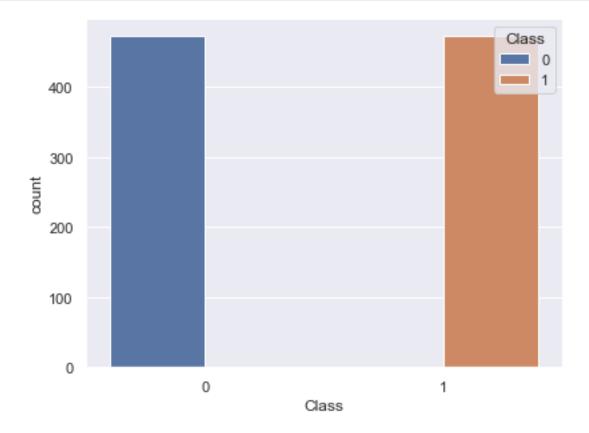
→iloc[:,-1]) #allfeatures , labels
```

[51]: y\_sample.value\_counts() #proporcion de datos luego de submuestreo

[51]: 1 473 0 473 Name: Class, dtype: int64 Concatenamos los conjuntos de datos en un solo set

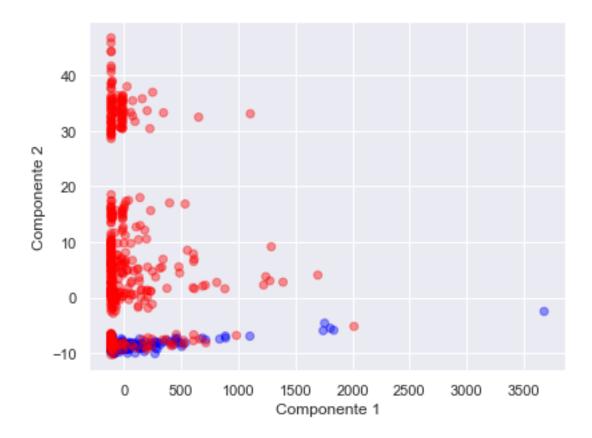
```
[53]: data_undersampled=pd.concat([X_sample,y_sample],axis=1)
```

[54]: ax=sns.countplot(x="Class",hue="Class",data=data\_undersampled)



Mostramos la dispersion de estos datos

[57]: plot\_scatter\_by\_class(data=data\_undersampled)



Guardamos los datos procesados en entrenamiento/test. OJO: No se realizo el escalado de datos

```
[68]: from sklearn.model_selection import train_test_split
     def save_balanced_data(data,name=None):
         import os
         columns=data.columns
         x_train,x_test,y_train,y_test=train_test_split(data.values[:,:-1],data.
      →values[:,-1],test_size=0.3,stratify=data.values[:,-1])
         train_data=np.concatenate([x_train,y_train.reshape(-1,1)],axis=1)
         test_data=np.concatenate([x_test,y_test.reshape(-1,1)],axis=1)
          #los transformo en dataframe y los guardo
         os.makedirs(f"./{name}",exist_ok=True)
         pd.DataFrame(train_data,columns=columns).to_csv(f"./{name}/train.
      ⇔csv",index=False)
         pd.DataFrame(test_data,columns=columns).to_csv(f"./{name}/test.
      print(f"./{name}/train.csv Guardado correctamente")
         print(f"./{name}/test.csv Guardado correctamente")
     save_balanced_data(data_undersampled,name="creditcard_undersampling")
```

```
./creditcard_undersampling/train.csv Guardado correctamente
./creditcard_undersampling/test.csv Guardado correctamente
```

Segundo Camino: Mantener la proporcion de datos y centrarse en las metricas Aqui dejamos los datos sin balancear para poder utilizarlos directamente en el modelo y evaluarlos con metricas como Recall, F1, Precision.

```
[69]: save_balanced_data(df_cleaned,name="creditcard_imbalanced")
```

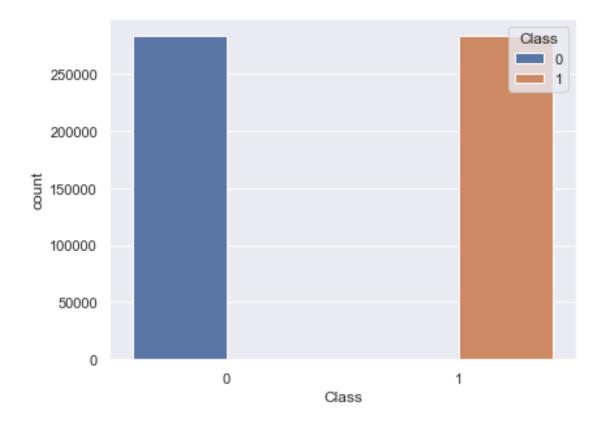
./creditcard\_imbalanced/train.csv Guardado correctamente ./creditcard\_imbalanced/test.csv Guardado correctamente

Los conjuntos balanceados como no balanceados se guardaron correctamente. Existen ahora dos posibles cambinos ya mencionados.

• Si el modelo no tiene buenos resultados en la evaluación con un conjunto, entonces tenemos otro. De esta manera medimos el impacto de la transformación de datos en el modelo

## 3ER Camino: Sobremuestreo de datos

• Para ello haremos un sobremuestreo usando la funcion SMOTE de la libreria imbalanced learn



Como podemos ver los datos se emparejaron los de mayor muestra, por lo que tambien decidimos guardar una muestra

```
[74]: save_balanced_data(data_oversampled,name="creditcard_oversampling")
```

- ./creditcard\_oversampling/train.csv Guardado correctamente
- ./creditcard\_oversampling/test.csv Guardado correctamente

#### 0.2 Modelado

• Esta fase se realiza en otro notebook, pero por temas de presentacion se realizara en el mismo.

Cuando queremos empezar a modelar, primero cargamos los datos.

- Definir la tecnica de modelado : Redes neuronales MLP
- Construir el modelo
- Validar el modelo

```
[75]: import numpy as np import pandas as pd #establecer una semilla para reprudicibilidad de resultados seed=42 seed=np.random.seed(seed)
```

```
[4]: def load_data(name=None):

data=pd.read_csv(name).values

return data[:,:-1],data[:,-1] #retornamos los conjuntos (features, labels)

[93]: x_train,y_train=load_data("./creditcard_imbalanced/train.csv") #cargamos losu

datos de entrenamiento
```

Dividimos los datos en pliegues de entrenamiento y validacion; para luego escalarlos

```
[92]: from sklearn.model_selection import train_test_split
      from sklearn.preprocessing import MinMaxScaler
      def partition_data(X,y,with_scale=False,split_size=0.2):
          Esta es una funcion generica que divide los datos en dos sets balanceados y_{\sqcup}
       \rightarrow luego da la opcion de escalarlos.
          El motivo de esta funcion es para ahorrar lineas de codigo en este proyecto_{\sqcup}
       \rightarrow complejo y usarlas con facilidad
          X: Conjunto de características en matrices numpy
          y: Etiquetas de prediccion en matrices numpy
          Return:
          (x_train, x_val, y_train, y_val) si with_scale=False
          (scale, x\_train, x\_val, y\_train, y\_val) si with_scale=True, devolviendo elu
       →objeto escalador 'scaler' """
       -x_train,x_val,y_train,y_val=train_test_split(X,y,test_size=split_size,random_state=42,shuff
          if with_scale:
               scaler=MinMaxScaler(feature_range=(0,1))
              scaler.fit(x_train,y_train);
              x_train=scaler.transform(x_train)
              x_val=scaler.transform(x_val)
              return scaler,x_train,x_val,y_train,y_val
          return x_train,x_val,y_train,y_val
```

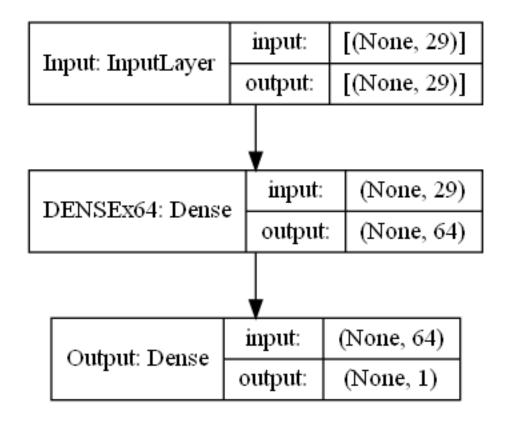
A continuación comenzamos a construir el modelo, para ellos cargamos las librearias inciales y herramientas para su implementación

### 0.2.1 CONSTRUCCION DEL MODELO BASE

El modelo base tiene como objetivo mostrar una prediccion inicial de los datos, para que luego un modelo posterior se desarrolle teniendo en cuenta que tiene que tener un puntaje mayor al obtenido por el base

Mostramos la arquitectura del modelo base.

```
[98]: from tensorflow.keras.utils import plot_model
    base_model=build_model()
    plot_model(base_model,"base_model.png",show_shapes=True)
[98]:
```



Vemos la descripcion de la capas y el numero de parametros entrenables

```
[99]: base_model.summary()
```

Model: "MODEL\_SEQUENTIAL"

Layer (type)	Output Shape	Param #		
DENSEx64 (Dense)	(None, 64)	1920		
Output (Dense)	(None, 1)	65		

Total params: 1,985 Trainable params: 1,985 Non-trainable params: 0

-----

Ahora establecemos **callbacks** tanto para detener el proceso de entrenamiento si no se obtienen buenos resultados por un numero determinado de epocas. Como tambien para obtener graficas del progeso del modelo durante el entrenamiento segun las epocas

```
[100]: early_stop=tf.keras.callbacks.EarlyStopping(
```

```
monitor="val_loss", #monitorizamos_
      → la funcion de perdida
                                        patience=10,
                                  )
[104]: #callbacks para las graficas
     def get_callback_tensorboard(name=None):
        import time
        name= int(time.time()) if name is None else f"{name}_{int(time.time())}"u
      \rightarrow#guardo el nombre y el tiempo
        log_dir=f"./tensorboard/fraud_detection/{name}"
        tb=tf.keras.callbacks.TensorBoard(log_dir=log_dir)
        return tb
[106]: BATCH_SIZE=64
     base model=build model()
     tensorboard_callbacks=get_callback_tensorboard("baseline")
     history=base_model.
      →fit(x_train,y_train,epochs=100,batch_size=BATCH_SIZE,validation_data=(x_val,y_val),callback
     Epoch 1/100
     accuracy: 0.9988 - recall: 0.2991 - val_loss: 0.0078 - val_accuracy: 0.9984 -
     val recall: 0.0303
     Epoch 2/100
     accuracy: 0.9984 - recall: 0.1698 - val_loss: 0.0052 - val_accuracy: 0.9989 -
     val_recall: 0.4242
     Epoch 3/100
     accuracy: 0.9987 - recall: 0.3551 - val loss: 0.0044 - val accuracy: 0.9991 -
     val_recall: 0.5303
     Epoch 4/100
     2483/2483 [============= ] - 3s 1ms/step - loss: 0.0039 -
     accuracy: 0.9991 - recall: 0.5738 - val_loss: 0.0043 - val_accuracy: 0.9991 -
     val_recall: 0.5303
     Epoch 5/100
     2483/2483 [============== ] - 3s 1ms/step - loss: 0.0040 -
     accuracy: 0.9993 - recall: 0.6681 - val_loss: 0.0039 - val_accuracy: 0.9992 -
     val_recall: 0.5909
     Epoch 6/100
     accuracy: 0.9992 - recall: 0.6530 - val loss: 0.0037 - val accuracy: 0.9993 -
     val_recall: 0.6818
     Epoch 7/100
     accuracy: 0.9991 - recall: 0.6285 - val loss: 0.0038 - val accuracy: 0.9993 -
```

```
val_recall: 0.7424
Epoch 8/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0028 -
accuracy: 0.9994 - recall: 0.7156 - val_loss: 0.0036 - val_accuracy: 0.9994 -
val recall: 0.7424
Epoch 9/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0038 -
accuracy: 0.9993 - recall: 0.7088 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val recall: 0.7273
Epoch 10/100
accuracy: 0.9994 - recall: 0.7266 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 11/100
2483/2483 [============ ] - 4s 1ms/step - loss: 0.0032 -
accuracy: 0.9994 - recall: 0.7251 - val loss: 0.0034 - val accuracy: 0.9994 -
val_recall: 0.7424
Epoch 12/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0035 -
accuracy: 0.9993 - recall: 0.7605 - val_loss: 0.0037 - val_accuracy: 0.9994 -
val recall: 0.7121
Epoch 13/100
accuracy: 0.9993 - recall: 0.7661 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 14/100
accuracy: 0.9993 - recall: 0.7293 - val_loss: 0.0035 - val_accuracy: 0.9993 -
val_recall: 0.7576
Epoch 15/100
accuracy: 0.9995 - recall: 0.7892 - val_loss: 0.0034 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 16/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0037 -
accuracy: 0.9993 - recall: 0.7277 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val recall: 0.7424
Epoch 17/100
accuracy: 0.9995 - recall: 0.7589 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 18/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0034 -
accuracy: 0.9994 - recall: 0.7408 - val loss: 0.0033 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 19/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9994 - recall: 0.7793 - val_loss: 0.0034 - val_accuracy: 0.9994 -
```

```
val_recall: 0.7424
Epoch 20/100
2483/2483 [============ ] - 4s 1ms/step - loss: 0.0032 -
accuracy: 0.9994 - recall: 0.7677 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val recall: 0.7424
Epoch 21/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0030 -
accuracy: 0.9994 - recall: 0.7624 - val_loss: 0.0035 - val_accuracy: 0.9994 -
val recall: 0.7424
Epoch 22/100
accuracy: 0.9994 - recall: 0.7579 - val loss: 0.0033 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 23/100
accuracy: 0.9995 - recall: 0.8062 - val loss: 0.0036 - val accuracy: 0.9993 -
val_recall: 0.7727
Epoch 24/100
accuracy: 0.9994 - recall: 0.8028 - val_loss: 0.0034 - val_accuracy: 0.9994 -
val recall: 0.7424
Epoch 25/100
accuracy: 0.9994 - recall: 0.7903 - val_loss: 0.0033 - val_accuracy: 0.9994 -
val_recall: 0.7727
Epoch 26/100
accuracy: 0.9993 - recall: 0.7570 - val loss: 0.0033 - val accuracy: 0.9994 -
val_recall: 0.7424
Epoch 27/100
accuracy: 0.9993 - recall: 0.7327 - val_loss: 0.0033 - val_accuracy: 0.9993 -
val_recall: 0.7727
Epoch 28/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0028 -
accuracy: 0.9995 - recall: 0.7866 - val_loss: 0.0032 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 29/100
accuracy: 0.9995 - recall: 0.8040 - val_loss: 0.0032 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 30/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9995 - recall: 0.8231 - val loss: 0.0032 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 31/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9994 - recall: 0.7851 - val_loss: 0.0036 - val_accuracy: 0.9993 -
```

```
val_recall: 0.7727
Epoch 32/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0026 -
accuracy: 0.9995 - recall: 0.8092 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 33/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9994 - recall: 0.7788 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 34/100
accuracy: 0.9994 - recall: 0.8041 - val loss: 0.0033 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 35/100
accuracy: 0.9994 - recall: 0.8118 - val loss: 0.0031 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 36/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0033 -
accuracy: 0.9994 - recall: 0.7855 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 37/100
accuracy: 0.9995 - recall: 0.8238 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 38/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0032 -
accuracy: 0.9994 - recall: 0.7550 - val loss: 0.0032 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 39/100
accuracy: 0.9994 - recall: 0.7657 - val_loss: 0.0034 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 40/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0032 -
accuracy: 0.9994 - recall: 0.7716 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 41/100
accuracy: 0.9995 - recall: 0.7686 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 42/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9993 - recall: 0.8042 - val loss: 0.0030 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 43/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9995 - recall: 0.8035 - val_loss: 0.0031 - val_accuracy: 0.9995 -
```

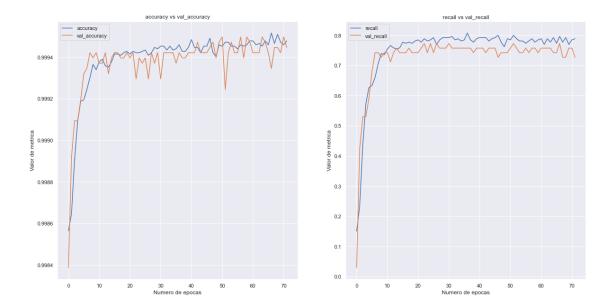
```
val_recall: 0.7424
Epoch 44/100
2483/2483 [============ ] - 4s 1ms/step - loss: 0.0033 -
accuracy: 0.9993 - recall: 0.7645 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 45/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0026 -
accuracy: 0.9995 - recall: 0.8132 - val_loss: 0.0030 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 46/100
accuracy: 0.9995 - recall: 0.8124 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 47/100
accuracy: 0.9994 - recall: 0.7731 - val loss: 0.0034 - val accuracy: 0.9994 -
val_recall: 0.7273
Epoch 48/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0030 -
accuracy: 0.9994 - recall: 0.7545 - val_loss: 0.0030 - val_accuracy: 0.9995 -
val recall: 0.7424
Epoch 49/100
accuracy: 0.9994 - recall: 0.7575 - val_loss: 0.0034 - val_accuracy: 0.9994 -
val_recall: 0.7424
Epoch 50/100
accuracy: 0.9994 - recall: 0.7885 - val loss: 0.0030 - val accuracy: 0.9995 -
val_recall: 0.7424
Epoch 51/100
accuracy: 0.9994 - recall: 0.7813 - val_loss: 0.0030 - val_accuracy: 0.9995 -
val_recall: 0.7576
Epoch 52/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0033 -
accuracy: 0.9994 - recall: 0.7995 - val_loss: 0.0038 - val_accuracy: 0.9992 -
val recall: 0.7727
Epoch 53/100
accuracy: 0.9995 - recall: 0.7607 - val_loss: 0.0032 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 54/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9994 - recall: 0.7302 - val loss: 0.0031 - val accuracy: 0.9995 -
val_recall: 0.7424
Epoch 55/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0035 -
accuracy: 0.9994 - recall: 0.7408 - val_loss: 0.0035 - val_accuracy: 0.9994 -
```

```
val_recall: 0.7424
Epoch 56/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0024 -
accuracy: 0.9996 - recall: 0.7988 - val_loss: 0.0029 - val_accuracy: 0.9994 -
val recall: 0.7576
Epoch 57/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0032 -
accuracy: 0.9994 - recall: 0.7400 - val_loss: 0.0033 - val_accuracy: 0.9995 -
val recall: 0.7424
Epoch 58/100
accuracy: 0.9995 - recall: 0.7961 - val loss: 0.0030 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 59/100
2483/2483 [=========== ] - 3s 1ms/step - loss: 0.0027 -
accuracy: 0.9994 - recall: 0.7496 - val loss: 0.0031 - val accuracy: 0.9995 -
val_recall: 0.7576
Epoch 60/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0027 -
accuracy: 0.9995 - recall: 0.7745 - val_loss: 0.0035 - val_accuracy: 0.9995 -
val recall: 0.7424
Epoch 61/100
accuracy: 0.9994 - recall: 0.7671 - val_loss: 0.0032 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 62/100
accuracy: 0.9995 - recall: 0.7843 - val loss: 0.0029 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 63/100
accuracy: 0.9993 - recall: 0.7371 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val_recall: 0.7576
Epoch 64/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0038 -
accuracy: 0.9992 - recall: 0.6999 - val_loss: 0.0032 - val_accuracy: 0.9995 -
val recall: 0.7576
Epoch 65/100
accuracy: 0.9994 - recall: 0.7800 - val_loss: 0.0034 - val_accuracy: 0.9995 -
val_recall: 0.7424
Epoch 66/100
2483/2483 [============= ] - 3s 1ms/step - loss: 0.0029 -
accuracy: 0.9994 - recall: 0.7620 - val loss: 0.0032 - val accuracy: 0.9994 -
val_recall: 0.7424
Epoch 67/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0028 -
accuracy: 0.9995 - recall: 0.8107 - val loss: 0.0034 - val accuracy: 0.9993 -
```

```
val_recall: 0.7727
Epoch 68/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0031 -
accuracy: 0.9994 - recall: 0.7189 - val_loss: 0.0031 - val_accuracy: 0.9994 -
val recall: 0.7273
Epoch 69/100
2483/2483 [============ ] - 3s 1ms/step - loss: 0.0025 -
accuracy: 0.9996 - recall: 0.8038 - val_loss: 0.0033 - val_accuracy: 0.9994 -
val recall: 0.7273
Epoch 70/100
accuracy: 0.9995 - recall: 0.7832 - val loss: 0.0032 - val accuracy: 0.9994 -
val_recall: 0.7576
Epoch 71/100
2483/2483 [=========== ] - 3s 1ms/step - loss: 0.0028 -
accuracy: 0.9994 - recall: 0.7767 - val loss: 0.0032 - val accuracy: 0.9995 -
val_recall: 0.7576
Epoch 72/100
2483/2483 [============== ] - 3s 1ms/step - loss: 0.0024 -
accuracy: 0.9995 - recall: 0.8394 - val_loss: 0.0030 - val_accuracy: 0.9994 -
val recall: 0.7273
```

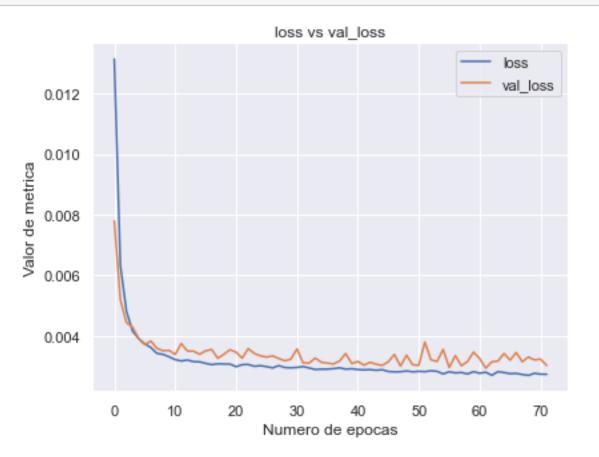
Obtenemos algunas graficas de rendimiento tanto en recall como loss. Para ver mas graficas tenemos a **tensorboard** que es mucho mejor que una version estatica de matplotlib.

• Veamos el contraste de el accuracy en entrenamiento y validacion



Veamos la evolucion de la funcion de perdida

[126]: plot\_metrics(history.history,metrics=["loss","val\_loss"])



#### Validacion: MODELO BASE

[149]: base\_model.evaluate(x\_val,y\_val)

[149]: [0.003015657654032111, 0.9994461536407471, 0.7272727489471436]

Evaluamos el modelo en el conjunto de validación y obtenemos un accuracy 99.99% y recall 72%

Le agregamos metricas classificacion para ver el rendimiento sobre los datos de validacion

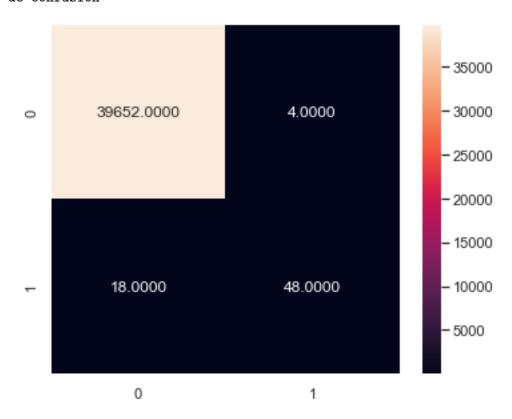
vemos la matriz de confusion para ver como van los resultados

## [151]: display\_report\_and\_matrix\_confusion(base\_model,x\_val,y\_val)

#### REPORTE DE CLASIFICACION

	precision	recall	f1-score	support
0.0	1.00	1.00	1.00	39656
1.0	0.92	0.73	0.81	66
accuracy			1.00	39722
macro avg	0.96	0.86	0.91	39722
weighted avg	1.00	1.00	1.00	39722

#### Matriz de confusion



El modelo base tiene buenos resultados en el conjunto de validacion. Al ser bueno lo llevaremos a la semifinal de modelos si logra pasar las expectativas en el conjunto de **Test**.

Entonces para ellos cargamos los datos de Test para evaluarlos y ver la realidad

#### EVALUACION DEL MODELO: MODELO BASE

• Esta etapa solo es necesaria si es que el modelo tiene buen rendemiento en los datos de validación y es definitivo, en caso contrario se necesita explorar nuevas configuraciones y arquitecturas del modelo. Hasta lograr un puntaje decente que conlleve al equilibrio entre el subajuste y sobreajuste

```
[136]: x_test,y_test=load_data("./creditcard_imbalanced/test.csv")

[137]: x_test=scaler_imb.transform(x_test) #los escalamos con los datos de_u → entrenamiento

Evaluamos el modelo

[139]: base_model.evaluate(x_test,y_test)
```

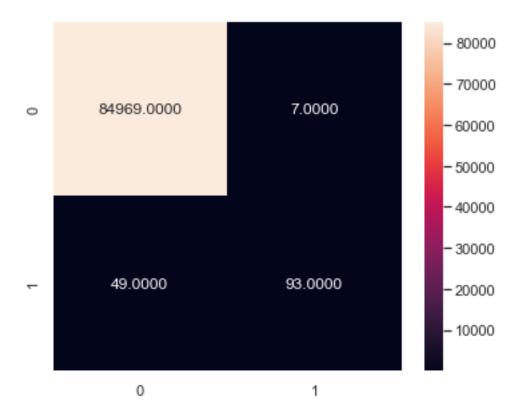
[139]: [0.003442350309342146, 0.9993420839309692, 0.6549295783042908]

Estamos viendo como tiene una precision del 99% pero al final un recall de 65%

[152]: display\_report\_and\_matrix\_confusion(base\_model,x\_test,y\_test)

REPORTE DE CL	ASIFICACION			
	precision	recall	f1-score	support
0.0	1.00	1.00	1.00	84976
1.0	0.93	0.65	0.77	142
accuracy			1.00	85118
macro avg	0.96	0.83	0.88	85118
weighted avg	1.00	1.00	1.00	85118

Matriz de confusion



Nada mal para ser el modelo base con solo 49 falsos negativos luego de 80 000 muestas de test. Los modelos que se implementen despues tienen que ser mucho mejor que este. • Guardamos el modelo con el formato **SavedModel** de tensorflow para contrastarlo luego con los demas modelo

```
[154]: tf.saved_model.save(base_model,"./best_endpoints/base_model")
    INFO:tensorflow:Assets written to: ./best_endpoints/base_model\assets
    Guardamos las medidas de escalamiento
[178]: import joblib
    joblib.dump(scaler_imb,"./best_endpoints/scaler_imbalanced.pkl")
[178]: ['./best_endpoints/scaler_imbalanced.pkl']
```

#### 0.2.2 MODELO V1.0 CON DATOS SOBREMUESTREADOS

• Una vez listo el modelo base podemos buscar manera de equilibrar el conjunto de datos, por lo que haremos un submuestreo de datos en favor a la clase minoritaria

```
[155]: x_train,y_train=load_data("./creditcard_oversampling/train.csv")
```

• Luego de los datos balanceados a partir del conjunto de entrenamiento, ahora podemos separar los datos de validación y train y escalarlos

```
[156]: scale_over,x_train,x_val,y_train,y_val=partition_data(x_train,y_train,with_scale=True)
```

• Ya equilibramos los datos. ahora realizaremos la busqueda de los mejores hiperparametros para la capa oculta del modelo con **keras tunner** 

```
[157]: import kerastuner as kt
      import tensorflow as tf
      n_features=x_train.shape[1] #el numero de columnas como dimension de entrada
      STEP UNITS=16 #las pasos de unidades de capa densa para probar los mejores,
       \rightarrow parametros
      def build_model_tuning(hp):
          model=tf.keras.models.Sequential()
          model.add(tf.keras.Input(shape=(n_features,),name="Input"))
          model.add(tf.keras.layers.Dense(
                         units=hp.
       activation="relu", name="HIDDEN LAYER"
          model.add(tf.keras.layers.Dense(1,activation="sigmoid",name="output"))
          #configuracion del modelo
          model.compile(optimizer=tf.keras.optimizers.Adam(lr=1e-3),
                       loss=tf.keras.losses.BinaryCrossentropy(),
                       metrics=metrics
                      )
```

#### return model

Creamos una instancia del sintonizador y realizamos el hipertuning

Realizamos el hipertuning del modelo

Best val\_recall So Far: 0.9882486462593079 Total elapsed time: 00h 15m 32s

INFO:tensorflow:Oracle triggered exit

Luego de la busqueda exhaustiva de hiperparametros, nuestro sintonizador nos devuelve los mejores hiperarametros.

El mejor numero de neuronas para la capa densa es de 176

• Entrene el modelo con los datos obtenidos de mejores hiperametros, esto con la finalidad de que ahora se obtengan el mejor numero de epocas de entrenamiento que tienen el **recall** mas alto

```
[161]: best_model=tuning.hypermodel.build(best_hps)
early_stop=tf.keras.callbacks.EarlyStopping(monitor="val_loss",patience=5) #se_\( \to detiene \) cuando la perdida de validacion no mejora
history=best_model.

ofit(x_train,y_train,epochs=100,batch_size=64,validation_data=(x_val,y_val),callbacks=[early of the mantenemos los callbacks para ahorrar tiempo en caso las metricas no_\( \to mejoren a medida que avancen los epochs \)
```

```
Epoch 1/100
4957/4957 [============== ] - 7s 1ms/step - loss: 0.2066 -
accuracy: 0.9508 - recall: 0.9234 - val loss: 0.1487 - val accuracy: 0.9460 -
val recall: 0.9001
Epoch 2/100
accuracy: 0.9497 - recall: 0.9244 - val_loss: 0.1133 - val_accuracy: 0.9540 -
val_recall: 0.9287
Epoch 3/100
accuracy: 0.9547 - recall: 0.9333 - val loss: 0.1044 - val accuracy: 0.9598 -
val_recall: 0.9485
Epoch 4/100
accuracy: 0.9582 - recall: 0.9406 - val_loss: 0.0976 - val_accuracy: 0.9619 -
val_recall: 0.9562
Epoch 5/100
4957/4957 [============== ] - 7s 1ms/step - loss: 0.1003 -
accuracy: 0.9610 - recall: 0.9460 - val_loss: 0.0946 - val_accuracy: 0.9648 -
val recall: 0.9637
Epoch 6/100
accuracy: 0.9636 - recall: 0.9497 - val_loss: 0.0852 - val_accuracy: 0.9680 -
val_recall: 0.9598
Epoch 7/100
accuracy: 0.9658 - recall: 0.9533 - val_loss: 0.0850 - val_accuracy: 0.9652 -
val_recall: 0.9433
Epoch 8/100
accuracy: 0.9669 - recall: 0.9552 - val_loss: 0.0771 - val_accuracy: 0.9699 -
val_recall: 0.9574
Epoch 9/100
accuracy: 0.9681 - recall: 0.9572 - val loss: 0.0804 - val accuracy: 0.9675 -
val recall: 0.9429
Epoch 10/100
accuracy: 0.9695 - recall: 0.9592 - val_loss: 0.0850 - val_accuracy: 0.9698 -
val_recall: 0.9819
Epoch 11/100
accuracy: 0.9710 - recall: 0.9616 - val_loss: 0.0828 - val_accuracy: 0.9660 -
val_recall: 0.9375
Epoch 12/100
accuracy: 0.9723 - recall: 0.9631 - val_loss: 0.0661 - val_accuracy: 0.9726 -
val_recall: 0.9573
```

```
Epoch 13/100
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0684 -
accuracy: 0.9732 - recall: 0.9650 - val loss: 0.0639 - val accuracy: 0.9779 -
val recall: 0.9766
Epoch 14/100
accuracy: 0.9746 - recall: 0.9672 - val_loss: 0.0644 - val_accuracy: 0.9760 -
val_recall: 0.9748
Epoch 15/100
accuracy: 0.9755 - recall: 0.9688 - val loss: 0.0595 - val accuracy: 0.9748 -
val_recall: 0.9596
Epoch 16/100
accuracy: 0.9767 - recall: 0.9703 - val_loss: 0.0523 - val_accuracy: 0.9807 -
val recall: 0.9794
Epoch 17/100
accuracy: 0.9784 - recall: 0.9732 - val_loss: 0.0486 - val_accuracy: 0.9825 -
val recall: 0.9769
Epoch 18/100
accuracy: 0.9799 - recall: 0.9756 - val_loss: 0.0462 - val_accuracy: 0.9821 -
val_recall: 0.9799
Epoch 19/100
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0502 -
accuracy: 0.9805 - recall: 0.9762 - val_loss: 0.0426 - val_accuracy: 0.9830 -
val_recall: 0.9781
Epoch 20/100
accuracy: 0.9813 - recall: 0.9778 - val_loss: 0.0446 - val_accuracy: 0.9809 -
val_recall: 0.9711
Epoch 21/100
accuracy: 0.9822 - recall: 0.9791 - val loss: 0.0524 - val accuracy: 0.9748 -
val recall: 0.9542
Epoch 22/100
accuracy: 0.9827 - recall: 0.9796 - val_loss: 0.0393 - val_accuracy: 0.9859 -
val_recall: 0.9888
Epoch 23/100
accuracy: 0.9834 - recall: 0.9814 - val_loss: 0.0402 - val_accuracy: 0.9875 -
val_recall: 0.9936
Epoch 24/100
accuracy: 0.9849 - recall: 0.9834 - val_loss: 0.0355 - val_accuracy: 0.9866 -
val_recall: 0.9862
```

```
Epoch 25/100
accuracy: 0.9853 - recall: 0.9839 - val loss: 0.0351 - val accuracy: 0.9872 -
val recall: 0.9831
Epoch 26/100
accuracy: 0.9855 - recall: 0.9843 - val_loss: 0.0344 - val_accuracy: 0.9890 -
val_recall: 0.9957
Epoch 27/100
accuracy: 0.9857 - recall: 0.9841 - val loss: 0.0353 - val accuracy: 0.9884 -
val_recall: 0.9961
Epoch 28/100
accuracy: 0.9869 - recall: 0.9860 - val_loss: 0.0309 - val_accuracy: 0.9884 -
val recall: 0.9846
Epoch 29/100
accuracy: 0.9872 - recall: 0.9864 - val_loss: 0.0336 - val_accuracy: 0.9874 -
val recall: 0.9799
Epoch 30/100
4957/4957 [============ ] - 6s 1ms/step - loss: 0.0331 -
accuracy: 0.9878 - recall: 0.9874 - val_loss: 0.0286 - val_accuracy: 0.9899 -
val_recall: 0.9873
Epoch 31/100
accuracy: 0.9877 - recall: 0.9876 - val_loss: 0.0392 - val_accuracy: 0.9845 -
val_recall: 0.9839
Epoch 32/100
accuracy: 0.9879 - recall: 0.9875 - val_loss: 0.0274 - val_accuracy: 0.9913 -
val_recall: 0.9969
Epoch 33/100
accuracy: 0.9888 - recall: 0.9890 - val loss: 0.0249 - val accuracy: 0.9921 -
val recall: 0.9923
Epoch 34/100
accuracy: 0.9888 - recall: 0.9885 - val_loss: 0.0431 - val_accuracy: 0.9794 -
val_recall: 0.9611
Epoch 35/100
accuracy: 0.9892 - recall: 0.9894 - val_loss: 0.0344 - val_accuracy: 0.9848 -
val_recall: 0.9739
Epoch 36/100
accuracy: 0.9899 - recall: 0.9905 - val_loss: 0.0382 - val_accuracy: 0.9844 -
val_recall: 0.9731
```

```
Epoch 37/100
accuracy: 0.9901 - recall: 0.9909 - val loss: 0.0255 - val accuracy: 0.9924 -
val recall: 0.9914
Epoch 38/100
accuracy: 0.9900 - recall: 0.9907 - val loss: 0.0215 - val accuracy: 0.9940 -
val_recall: 0.9971
Epoch 39/100
accuracy: 0.9907 - recall: 0.9916 - val loss: 0.0229 - val accuracy: 0.9929 -
val_recall: 0.9950
Epoch 40/100
accuracy: 0.9912 - recall: 0.9918 - val_loss: 0.0233 - val_accuracy: 0.9929 -
val recall: 0.9950
Epoch 41/100
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0263 -
accuracy: 0.9911 - recall: 0.9918 - val_loss: 0.0206 - val_accuracy: 0.9935 -
val recall: 0.9919
Epoch 42/100
accuracy: 0.9910 - recall: 0.9916 - val_loss: 0.0260 - val_accuracy: 0.9894 -
val recall: 0.9822
Epoch 43/100
accuracy: 0.9910 - recall: 0.9916 - val_loss: 0.0383 - val_accuracy: 0.9834 -
val_recall: 0.9705
Epoch 44/100
accuracy: 0.9914 - recall: 0.9921 - val_loss: 0.0190 - val_accuracy: 0.9943 -
val_recall: 0.9961
Epoch 45/100
accuracy: 0.9911 - recall: 0.9922 - val loss: 0.0253 - val accuracy: 0.9913 -
val recall: 0.9978
Epoch 46/100
accuracy: 0.9918 - recall: 0.9928 - val_loss: 0.0211 - val_accuracy: 0.9940 -
val_recall: 0.9924
Epoch 47/100
accuracy: 0.9924 - recall: 0.9936 - val_loss: 0.0261 - val_accuracy: 0.9888 -
val_recall: 0.9821
Epoch 48/100
accuracy: 0.9924 - recall: 0.9933 - val_loss: 0.0192 - val_accuracy: 0.9940 -
val_recall: 0.9970
```

Una vez culminado el entrenamiento procedemos a identificar el **epoch** donde obtuvo mas puntaje la metrica **RECALL** que es recuperacion de precision. Esto calcula pares de recuperacion/precision para diferentes umbrales de probabilidad.

Observacion: En el entrenamiento anterior el entrenamiento se detuvo en el epochs=49 debido a que **val\_loss** no mejoraba por mas de 10 epocas

```
[162]: n_epochs=np.argmax(history.history["val_recall"])+1 #busca la ubicacion que⊔

→ posee el valor mas alto basandose en su indice+1

print(f"El numero adecuado de epocas de entrenamiento es de : {n_epochs}")
```

El numero adecuado de epocas de entrenamiento es de : 45

Esta vez continuamos el entrenamiento sin callbacks EarlyStpping debido a que no tenemos nada que monitorear para la mejora. Tenemos los mejores hiperparametros y el numero de epocas apropiado. Ahora si, a realizar un entrenamiento limpio.

```
[163]: |tensorboard_callback=get_callback_tensorboard("oversample_model") #incluimosu
     →tensorboard para mostrar la grafica asociada al entrenamiento
     best_model=tuning.hypermodel.build(best_hps)
     history=best_model.
      →fit(x_train,y_train,epochs=n_epochs,batch_size=64,validation_data=(x_val,y_val),callbacks=[
    Epoch 1/45
    accuracy: 0.9571 - recall: 0.9264 - val_loss: 0.1283 - val_accuracy: 0.9501 -
    val_recall: 0.9358
    Epoch 2/45
    accuracy: 0.9498 - recall: 0.9244 - val_loss: 0.1177 - val_accuracy: 0.9541 -
    val_recall: 0.9455
    Epoch 3/45
    accuracy: 0.9540 - recall: 0.9325 - val_loss: 0.1025 - val_accuracy: 0.9581 -
    val_recall: 0.9387
    Epoch 4/45
    accuracy: 0.9591 - recall: 0.9410 - val_loss: 0.1013 - val_accuracy: 0.9597 -
    val_recall: 0.9284
    Epoch 5/45
    4957/4957 [============ ] - 7s 1ms/step - loss: 0.0985 -
    accuracy: 0.9613 - recall: 0.9463 - val_loss: 0.0898 - val_accuracy: 0.9654 -
    val_recall: 0.9456
    Epoch 6/45
    4957/4957 [============= ] - 7s 1ms/step - loss: 0.0923 -
```

```
accuracy: 0.9644 - recall: 0.9513 - val_loss: 0.0932 - val_accuracy: 0.9630 -
val_recall: 0.9335
Epoch 7/45
accuracy: 0.9659 - recall: 0.9536 - val loss: 0.0798 - val accuracy: 0.9678 -
val recall: 0.9491
Epoch 8/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0818 -
accuracy: 0.9682 - recall: 0.9580 - val_loss: 0.0851 - val_accuracy: 0.9647 -
val recall: 0.9377
Epoch 9/45
accuracy: 0.9702 - recall: 0.9604 - val_loss: 0.0724 - val_accuracy: 0.9709 -
val recall: 0.9536
Epoch 10/45
accuracy: 0.9713 - recall: 0.9624 - val_loss: 0.0648 - val_accuracy: 0.9750 -
val_recall: 0.9682
Epoch 11/45
accuracy: 0.9728 - recall: 0.9648 - val_loss: 0.0745 - val_accuracy: 0.9735 -
val recall: 0.9878
Epoch 12/45
accuracy: 0.9751 - recall: 0.9681 - val_loss: 0.0601 - val_accuracy: 0.9752 -
val_recall: 0.9619
Epoch 13/45
accuracy: 0.9762 - recall: 0.9697 - val_loss: 0.0581 - val_accuracy: 0.9757 -
val_recall: 0.9638
Epoch 14/45
accuracy: 0.9780 - recall: 0.9725 - val loss: 0.0547 - val accuracy: 0.9801 -
val_recall: 0.9842
Epoch 15/45
accuracy: 0.9791 - recall: 0.9745 - val_loss: 0.0474 - val_accuracy: 0.9821 -
val_recall: 0.9776
Epoch 16/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0524 -
accuracy: 0.9799 - recall: 0.9757 - val_loss: 0.1185 - val_accuracy: 0.9552 -
val_recall: 0.9118
Epoch 17/45
accuracy: 0.9804 - recall: 0.9764 - val_loss: 0.0439 - val_accuracy: 0.9848 -
val_recall: 0.9877
Epoch 18/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0481 -
```

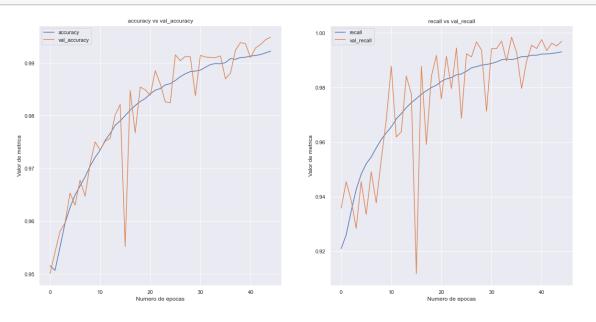
```
accuracy: 0.9813 - recall: 0.9779 - val_loss: 0.0523 - val_accuracy: 0.9768 -
val_recall: 0.9591
Epoch 19/45
accuracy: 0.9820 - recall: 0.9790 - val loss: 0.0385 - val accuracy: 0.9854 -
val recall: 0.9840
Epoch 20/45
4957/4957 [=========== ] - 7s 1ms/step - loss: 0.0427 -
accuracy: 0.9837 - recall: 0.9814 - val_loss: 0.0434 - val_accuracy: 0.9849 -
val_recall: 0.9917
Epoch 21/45
accuracy: 0.9844 - recall: 0.9824 - val_loss: 0.0410 - val_accuracy: 0.9839 -
val recall: 0.9758
Epoch 22/45
accuracy: 0.9848 - recall: 0.9826 - val_loss: 0.0342 - val_accuracy: 0.9885 -
val_recall: 0.9914
Epoch 23/45
accuracy: 0.9848 - recall: 0.9830 - val_loss: 0.0352 - val_accuracy: 0.9860 -
val recall: 0.9795
Epoch 24/45
accuracy: 0.9858 - recall: 0.9845 - val_loss: 0.0480 - val_accuracy: 0.9826 -
val_recall: 0.9945
Epoch 25/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0379 -
accuracy: 0.9857 - recall: 0.9846 - val_loss: 0.0403 - val_accuracy: 0.9825 -
val_recall: 0.9687
Epoch 26/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0367 -
accuracy: 0.9862 - recall: 0.9854 - val loss: 0.0270 - val accuracy: 0.9916 -
val_recall: 0.9923
Epoch 27/45
accuracy: 0.9876 - recall: 0.9874 - val_loss: 0.0283 - val_accuracy: 0.9904 -
val_recall: 0.9912
Epoch 28/45
accuracy: 0.9878 - recall: 0.9873 - val_loss: 0.0287 - val_accuracy: 0.9913 -
val_recall: 0.9967
Epoch 29/45
accuracy: 0.9881 - recall: 0.9880 - val_loss: 0.0291 - val_accuracy: 0.9912 -
val_recall: 0.9937
Epoch 30/45
```

```
accuracy: 0.9886 - recall: 0.9884 - val_loss: 0.0369 - val_accuracy: 0.9838 -
val_recall: 0.9713
Epoch 31/45
accuracy: 0.9883 - recall: 0.9885 - val loss: 0.0258 - val accuracy: 0.9914 -
val recall: 0.9942
Epoch 32/45
4957/4957 [=========== ] - 7s 1ms/step - loss: 0.0294 -
accuracy: 0.9892 - recall: 0.9895 - val_loss: 0.0266 - val_accuracy: 0.9911 -
val recall: 0.9942
Epoch 33/45
accuracy: 0.9896 - recall: 0.9900 - val_loss: 0.0266 - val_accuracy: 0.9910 -
val recall: 0.9970
Epoch 34/45
accuracy: 0.9894 - recall: 0.9899 - val_loss: 0.0253 - val_accuracy: 0.9910 -
val_recall: 0.9897
Epoch 35/45
accuracy: 0.9900 - recall: 0.9904 - val_loss: 0.0269 - val_accuracy: 0.9913 -
val recall: 0.9984
Epoch 36/45
accuracy: 0.9901 - recall: 0.9905 - val_loss: 0.0354 - val_accuracy: 0.9870 -
val_recall: 0.9928
Epoch 37/45
accuracy: 0.9905 - recall: 0.9907 - val_loss: 0.0283 - val_accuracy: 0.9881 -
val_recall: 0.9796
Epoch 38/45
accuracy: 0.9907 - recall: 0.9912 - val loss: 0.0215 - val accuracy: 0.9924 -
val_recall: 0.9897
Epoch 39/45
accuracy: 0.9907 - recall: 0.9914 - val_loss: 0.0200 - val_accuracy: 0.9939 -
val_recall: 0.9955
Epoch 40/45
4957/4957 [============== ] - 7s 1ms/step - loss: 0.0250 -
accuracy: 0.9912 - recall: 0.9921 - val_loss: 0.0213 - val_accuracy: 0.9937 -
val_recall: 0.9943
Epoch 41/45
accuracy: 0.9910 - recall: 0.9918 - val_loss: 0.0265 - val_accuracy: 0.9910 -
val_recall: 0.9975
Epoch 42/45
```

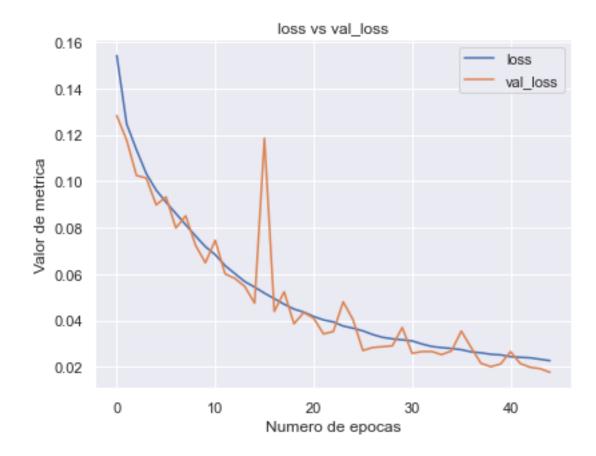
Ahora analizamos las metricas de desempeño del modelo a traves del entrenamiento

```
[165]: fig,(ax1,ax2)=plt.subplots(1,2,figsize=(20,10))

plot_metrics(history.history,metrics=["accuracy","val_accuracy"],ax=ax1)
plot_metrics(history.history,metrics=["recall","val_recall"],ax=ax2)
```



```
[166]: #tenemos la grafica de la funcion de perdida plot_metrics(history.history,metrics=["loss","val_loss"])
```



Una vez entrenado el mejor modelo procedemos a realizar la validacion del modelo

#### VALIDACION DEL MODELO: MODELO SOBREMUESTREADO

• Veamos como se comporto el modelo durante el entrenamiento y su contraste con los datos de validación

```
[169]: best_model.evaluate(x_val,y_val)
```

[169]: [0.01762423664331436, 0.9948809146881104, 0.9968730211257935]

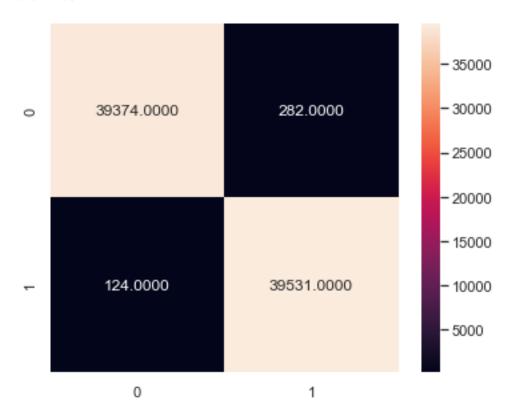
El modelo esta **generalizando muy bien en los datos de validacion** y es algo normal debido a que se entrenó y sintonizó con dichos datos. Pero a diferencia del **modelo base**, esta mucho mejor.

A continuación veamos las metricas relacionadas a los reportes y la matriz de confusion

REPORTE DE CLASIFICACION precision recall f1-score support

0.0	1.00	0.99	0.99	39656
1.0	0.99	1.00	0.99	39655
accuracy			0.99	79311
macro avg	0.99	0.99	0.99	79311
weighted avg	0.99	0.99	0.99	79311

Matriz de confusion



Como era de esperar, los datos se balancearon y por ello incremento el factor de errores y aciertos. Ahora tenemos 124 falsos negativos (transacciones fraudulentas que dejamos ir), como tambien tenemos mas de **35 000 transacciones que identificamos con exito**!

Por otro lado algo de resaltar en este conjunto de validación es que tenemos mas Falsos positivos que negativos y esta bien.

#### EVALUACION DEL MODELO CON SOBREMUESTREO

• Para ello cargamos los datos de test guardados en otro archivo ./credit-card\_oversampling/test.cav

[170]: x\_test,y\_test=load\_data("./creditcard\_oversampling/test.csv")

[171]: x\_test=scale\_over.transform(x\_test)

[172]: best\_model.evaluate(x\_test,y\_test)

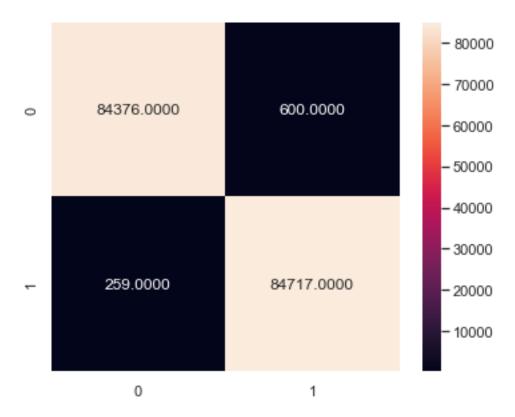
[172]: [0.01861482672393322, 0.9949456453323364, 0.9969520568847656]

Excelente!. Tenemos una puntuacion de **Accuracy 99.49**% sobre datos nunca antes vistos y un **Recall de 99.7**%. Desde luego unas excelentes metricas sobre datos de Test

[173]: display\_report\_and\_matrix\_confusion(best\_model,x\_test,y\_test)

REPORTE DE CL	ASIFICACION precision	recall	f1-score	support
0.0	1.00	0.99	0.99	84976
1.0	0.99	1.00	0.99	84976
accuracy			0.99	169952
macro avg	0.99	0.99	0.99	169952
weighted avg	0.99	0.99	0.99	169952

Matriz de confusion



- TP (verdadero positivo): 84376 datos predecidos como positivos correctamente
- FP (Falso positivo) : 600 datos predecidos falsamente como positivos
- FN (Falso Negativo): 259 datos predecidos como negativos incorrectamente
- TN (verdadero positivo) : 84717 datos predecidos como positivos correctamente

El modelo da resultados excelentes. De mas de 16 000 muestras sobremuestreadas. solo 250 no se detectaron a tiempo, pero en su lugar mas de 80 000 muestras fraudulentas fueron atrapadas exitosamente.

• El modelo tiene una precision del 99% y tasa de recall de 99%. Desde luego fue un mejor modelo

```
[175]: tf.saved_model.save(best_model,"./best_endpoints/model_oversampling")

→#guardamos el modelo
```

INFO:tensorflow:Assets written to: ./best\_endpoints/model\_oversampling\assets
Las medidas de escalamiento tambien se guardan

```
[176]: import joblib

joblib.dump(scale_over,"./best_endpoints/scaler_oversampling.pkl")
```

[176]: ['./best\_endpoints/scaler\_oversampling.pkl']

#### 0.2.3 MODELO v2.0 CON DATOS SIN BALANCEAR

• Esta vez se intentara mejorar el modelo base sin balancear a traves de un sintonizador de hiperparametros

Para ello realizaremos los mismos pasos de carga de datos, separacion y normalizacion de datos

```
[196]: x_train,y_train=load_data("./creditcard_imbalanced/train.csv")
scaler_imbv2,x_train,x_val,y_train,y_val=partition_data(x_train,y_train,with_scale=True,split_
→2) #20% de datos de validacion
```

Una vez obtenido los datos, llamo al sintonizador de hiperparametros, y lo configuro

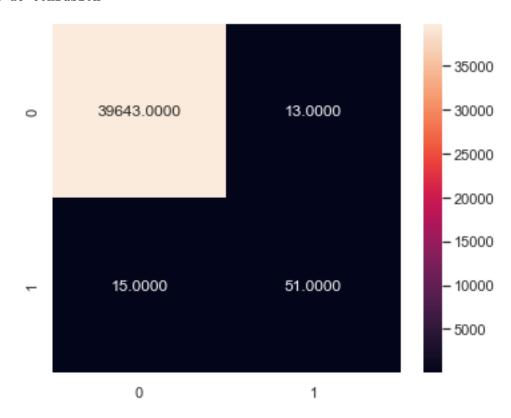
```
[199]: | early_stopping=tf.keras.callbacks.EarlyStopping(monitor="val_loss",patience=10)
      →#si el entrenamiento no mejora siginificativamente durante 10 epocas lou
       \rightarrow detengo
[200]: tuning.
      →search(x_train,y_train,epochs=100,batch_size=64,validation_data=(x_val,y_val),callbacks=[ea
     Trial 30 Complete [00h 00m 36s]
     val_recall: 0.7424242496490479
     Best val_recall So Far: 0.7727272510528564
     Total elapsed time: 00h 08m 11s
     INFO:tensorflow:Oracle triggered exit
[201]: best_hps=tuning.get_best_hyperparameters(num_trials=1)[0]
      print(f"Las mejores neuronas para la capa densa son: {best_hps.get('units')}")
     Las mejores neuronas para la capa densa son: 304
     Ahora construimos el modelo usando el mejor modelo encontrado
[202]: model imbalanced=tuning.get best models(num models=1)[0]
[203]: model_imbalanced.summary()
     Model: "sequential"
     Layer (type)
                              Output Shape
                                                     Param #
     ______
     HIDDEN_LAYER (Dense)
                              (None, 304)
                                                     9120
     output (Dense)
                               (None, 1)
                                                     305
     _____
     Total params: 9,425
     Trainable params: 9,425
     Non-trainable params: 0
     VALIDACION DEL MODELO: MODELO DESBALANCEADO BASE MEJORADO
     Validamos el modelo
[204]: loss_val,acc_val,recall_val=model_imbalanced.evaluate(x_val,y_val)
     accuracy: 0.9993 - recall: 0.6756
[205]: print(f"Accuracy {acc val:0.10f}")
      print(f"Recall {recall_val:0.10f}")
```

Accuracy 0.9993076921 Recall 0.7196969986

[206]: display\_report\_and\_matrix\_confusion(model\_imbalanced,x\_val,y\_val)

			SIFICACION	REPORTE DE CLAS
support	f1-score	recall	precision	p
39656	1.00	1.00	1.00	0.0
66	0.78	0.77	0.80	1.0
39722	1.00			accuracy
39722	0.89	0.89	0.90	macro avg
39722	1.00	1.00	1.00	weighted avg

Matriz de confusion



• Tenemos un **accuracy 99.84**% y un recall (que es nuestro objetivo) de **77**% en los datos de validacion. Mejor que el modelo base en la etapa de validacion

### **EVALUACION DEL MODELO V2**

```
[207]: #primero cargamos los datos y escalamos
x_test,y_test=load_data("./creditcard_imbalanced/test.csv")
x_test=scaler_imbv2.transform(x_test)
```

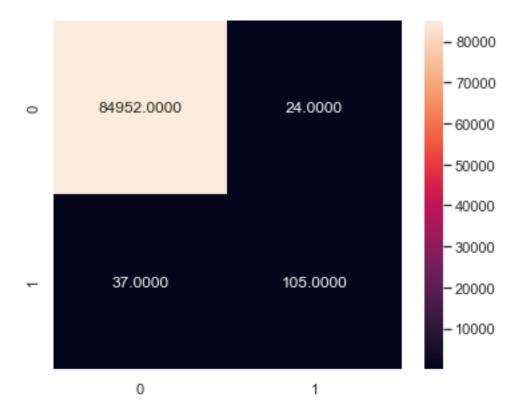
[208]: model\_imbalanced.evaluate(x\_test,y\_test)

[208]: [0.003884269157424569, 0.9992833733558655, 0.7394366264343262]

[209]: display\_report\_and\_matrix\_confusion(model\_imbalanced,x\_test,y\_test)

#### REPORTE DE CLASIFICACION precision recall f1-score support 0.0 1.00 84976 1.00 1.00 1.0 0.81 0.74 0.77 142 1.00 85118 accuracy macro avg 0.91 0.87 0.89 85118 weighted avg 1.00 1.00 85118 1.00

#### Matriz de confusion



En comparacion con el modelo base tuvo un accuracy de 99.9% y un recall superior de 73%, es mejor que el modelo base.

Obtuvo menor Falsos negativos, pero gano mas falsos positivos, que haran que una transaccion comun sea considerada fraude en al gunos clientes. Es mas sensible al fraude a un costo de ser desconfiado de las verdaderas transacciones confiables

[213]: ['./best\_endpoints/scaler\_best\_imbalanced.pkl']

# 0.2.4 MODELO v3.0 CON DATOS BALANCEADOS POR METODO DE SUBMUESTREO

• Esto nos permite tener la proporcion de clases pertenecientes a fraude y No fraude equilibradas mediante la reduccion de la cantidad de muestras mayoritarias al nivel de clases Minoritarias. Tomelo como el efecto inverso de un Sobre muestreo

```
[214]: #cargamos los datos del sobremuestreo obtenidos en la fase de transformacion de⊔

→ datos/empacado

x_train,y_train=load_data("./creditcard_undersampling/train.csv")

scaler_usmp,x_train,x_val,y_train,y_val=partition_data(x_train,y_train,with_scale=True,split_s

→2)
```

Teniendo los datos listos, crearemos el modelo y su sintonizador para obtener los mejores parametros para el entrenamiento

```
[215]: BATCH_SIZE=42
STEP_UNITS=2 #Esta variable se encuentra dentro del las funcion que construye⊔
→el modelo
```

```
tuning.
       →search(x_train,y_train,epochs=150,batch_size=BATCH_SIZE,validation_data=(x_val,y_val),callb
      Trial 30 Complete [00h 00m 01s]
      val_recall: 0.8181818127632141
      Best val_recall So Far: 1.0
      Total elapsed time: 00h 00m 36s
      INFO:tensorflow:Oracle triggered exit
[223]: best_hps=tuning.get_best_hyperparameters(num_trials=1)[0]
[224]: print("El mejor numero de neuronas para la capa oculta es de", best hps.

→get("units"))
      El mejor numero de neuronas para la capa oculta es de 294
      Entonces obtenemos la mejor combinacion de hiperparametros y reconstruimos el modelo, ahora
      con la intencion de obtener el mejor numero de epochs para el modelo
[225]: #existen dos maneras de hacerlo
      model_unsampling=tuning.hypermodel.build(best_hps) #a traves de la construccion_
       \rightarrow de sus mejores hiperparametros
      #model_unsampling=tuning.get_best_models(num_models=1)[0] #obteniendo el mejoru
       \rightarrow modelo
      La configuración para la versión 3 del modelo es:
[226]: model_unsampling.summary()
      Model: "sequential"
      Layer (type)
                                Output Shape
                                                           Param #
      ______
      HIDDEN_LAYER (Dense)
                                  (None, 294)
                                                           8820
      output (Dense)
                                                           295
                                  (None, 1)
      ______
      Total params: 9,115
      Trainable params: 9,115
      Non-trainable params: 0
        • Obtenemos el mejor epochs
[227]: early_stopping=tf.keras.callbacks.EarlyStopping(monitor="val_loss",patience=10)
      history=model_unsampling.
       →fit(x_train,y_train,epochs=150,batch_size=BATCH_SIZE,validation_data=(x_val,y_val),callback
```

```
Epoch 1/150
0.7110 - recall: 0.4197 - val_loss: 0.6129 - val_accuracy: 0.7444 - val_recall:
0.8636
Epoch 2/150
0.8615 - recall: 0.8106 - val_loss: 0.5504 - val_accuracy: 0.8045 - val_recall:
0.6061
Epoch 3/150
0.8314 - recall: 0.6734 - val loss: 0.5070 - val accuracy: 0.8346 - val recall:
0.6667
Epoch 4/150
0.8079 - recall: 0.6125 - val_loss: 0.4667 - val_accuracy: 0.8872 - val_recall:
0.7879
Epoch 5/150
0.8898 - recall: 0.7779 - val_loss: 0.4259 - val_accuracy: 0.8797 - val_recall:
0.7576
Epoch 6/150
0.8943 - recall: 0.7827 - val_loss: 0.3945 - val_accuracy: 0.8872 - val_recall:
0.7879
Epoch 7/150
0.8977 - recall: 0.7827 - val_loss: 0.3651 - val_accuracy: 0.8947 - val_recall:
0.7879
Epoch 8/150
0.8931 - recall: 0.7908 - val_loss: 0.3422 - val_accuracy: 0.8872 - val_recall:
0.7727
Epoch 9/150
0.8757 - recall: 0.7639 - val loss: 0.3302 - val accuracy: 0.8797 - val recall:
0.7576
Epoch 10/150
0.8961 - recall: 0.7914 - val_loss: 0.3059 - val_accuracy: 0.8947 - val_recall:
0.8030
Epoch 11/150
0.9068 - recall: 0.8140 - val_loss: 0.2982 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 12/150
0.9115 - recall: 0.8261 - val_loss: 0.2798 - val_accuracy: 0.8947 - val_recall:
0.8030
```

```
Epoch 13/150
0.9070 - recall: 0.8162 - val_loss: 0.2686 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 14/150
0.9087 - recall: 0.8219 - val_loss: 0.2596 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 15/150
0.8970 - recall: 0.7940 - val loss: 0.2514 - val accuracy: 0.9023 - val recall:
0.8182
Epoch 16/150
0.9190 - recall: 0.8437 - val_loss: 0.2443 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 17/150
0.8987 - recall: 0.7997 - val_loss: 0.2437 - val_accuracy: 0.8947 - val_recall:
0.8030
Epoch 18/150
0.9081 - recall: 0.8212 - val_loss: 0.2356 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 19/150
0.9173 - recall: 0.8442 - val_loss: 0.2314 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 20/150
0.9337 - recall: 0.8776 - val_loss: 0.2287 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 21/150
0.9380 - recall: 0.8799 - val loss: 0.2189 - val accuracy: 0.9173 - val recall:
0.8485
Epoch 22/150
0.9358 - recall: 0.8786 - val_loss: 0.2192 - val_accuracy: 0.9098 - val_recall:
0.8333
Epoch 23/150
0.9342 - recall: 0.8683 - val_loss: 0.2305 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 24/150
0.9369 - recall: 0.8824 - val_loss: 0.2097 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 25/150
0.9287 - recall: 0.8635 - val_loss: 0.2051 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 26/150
0.9482 - recall: 0.8981 - val_loss: 0.2063 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 27/150
0.9228 - recall: 0.8500 - val loss: 0.2037 - val accuracy: 0.9248 - val recall:
0.8636
Epoch 28/150
0.9239 - recall: 0.8645 - val_loss: 0.2064 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 29/150
0.9354 - recall: 0.8740 - val_loss: 0.2034 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 30/150
0.9429 - recall: 0.8896 - val_loss: 0.1956 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 31/150
0.9327 - recall: 0.8758 - val_loss: 0.1989 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 32/150
0.9339 - recall: 0.9058 - val_loss: 0.1897 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 33/150
0.9403 - recall: 0.8907 - val loss: 0.1894 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 34/150
0.9351 - recall: 0.8845 - val_loss: 0.1937 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 35/150
0.9393 - recall: 0.8790 - val_loss: 0.1864 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 36/150
0.9227 - recall: 0.8537 - val_loss: 0.1860 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 37/150
0.9402 - recall: 0.8882 - val_loss: 0.1850 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 38/150
0.9416 - recall: 0.9076 - val_loss: 0.1830 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 39/150
0.9371 - recall: 0.8810 - val loss: 0.1852 - val accuracy: 0.9398 - val recall:
0.8939
Epoch 40/150
0.9376 - recall: 0.8884 - val_loss: 0.1826 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 41/150
0.9418 - recall: 0.8899 - val_loss: 0.1805 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 42/150
0.9447 - recall: 0.8953 - val_loss: 0.1850 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 43/150
0.9236 - recall: 0.8918 - val_loss: 0.1934 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 44/150
0.9297 - recall: 0.8692 - val_loss: 0.1776 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 45/150
0.9499 - recall: 0.9073 - val loss: 0.1768 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 46/150
0.9538 - recall: 0.9170 - val_loss: 0.1930 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 47/150
0.9187 - recall: 0.8789 - val_loss: 0.1781 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 48/150
0.9303 - recall: 0.8960 - val_loss: 0.1849 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 49/150
0.9210 - recall: 0.8556 - val_loss: 0.1761 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 50/150
0.9500 - recall: 0.9049 - val_loss: 0.1752 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 51/150
0.9463 - recall: 0.9052 - val loss: 0.1730 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 52/150
0.9493 - recall: 0.9022 - val_loss: 0.1756 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 53/150
0.9354 - recall: 0.8864 - val_loss: 0.1761 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 54/150
0.9365 - recall: 0.8925 - val_loss: 0.1722 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 55/150
0.9357 - recall: 0.8980 - val_loss: 0.1722 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 56/150
0.9375 - recall: 0.8759 - val_loss: 0.1863 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 57/150
0.9391 - recall: 0.9179 - val loss: 0.1722 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 58/150
0.9359 - recall: 0.8863 - val_loss: 0.1723 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 59/150
0.9367 - recall: 0.8721 - val_loss: 0.1851 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 60/150
0.9333 - recall: 0.8957 - val_loss: 0.1708 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 61/150
0.9216 - recall: 0.8785 - val_loss: 0.2061 - val_accuracy: 0.9323 - val_recall:
0.8636
Epoch 62/150
0.9455 - recall: 0.8988 - val_loss: 0.1854 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 63/150
0.9340 - recall: 0.8860 - val loss: 0.1748 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 64/150
0.9432 - recall: 0.8898 - val_loss: 0.1709 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 65/150
0.9361 - recall: 0.8880 - val_loss: 0.1704 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 66/150
0.9413 - recall: 0.8914 - val_loss: 0.1742 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 67/150
0.9449 - recall: 0.9062 - val_loss: 0.1693 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 68/150
0.9278 - recall: 0.8631 - val_loss: 0.1689 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 69/150
0.9284 - recall: 0.8919 - val loss: 0.1720 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 70/150
0.9262 - recall: 0.8696 - val_loss: 0.1689 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 71/150
0.9402 - recall: 0.8869 - val_loss: 0.1690 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 72/150
0.9412 - recall: 0.8877 - val_loss: 0.1696 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 73/150
0.9424 - recall: 0.8937 - val loss: 0.1752 - val accuracy: 0.9323 - val recall:
0.8939
Epoch 74/150
0.9410 - recall: 0.9037 - val_loss: 0.1743 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 75/150
0.9445 - recall: 0.8968 - val loss: 0.1882 - val accuracy: 0.9323 - val recall:
0.9394
Epoch 76/150
0.9335 - recall: 0.9233 - val_loss: 0.1708 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 77/150
0.9458 - recall: 0.9031 - val_loss: 0.1665 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 78/150
0.9552 - recall: 0.9192 - val_loss: 0.1706 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 79/150
0.9465 - recall: 0.9150 - val_loss: 0.1671 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 80/150
0.9429 - recall: 0.9072 - val_loss: 0.1663 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 81/150
0.9411 - recall: 0.9135 - val loss: 0.1736 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 82/150
0.9433 - recall: 0.9049 - val_loss: 0.1656 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 83/150
0.9298 - recall: 0.8760 - val_loss: 0.1714 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 84/150
0.9412 - recall: 0.9107 - val_loss: 0.1719 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 85/150
0.9464 - recall: 0.9010 - val_loss: 0.1651 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 86/150
0.9396 - recall: 0.9090 - val_loss: 0.1670 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 87/150
0.9416 - recall: 0.9079 - val loss: 0.1731 - val accuracy: 0.9398 - val recall:
0.9091
Epoch 88/150
0.9334 - recall: 0.9046 - val_loss: 0.1666 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 89/150
0.9472 - recall: 0.9014 - val_loss: 0.1641 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 90/150
0.9393 - recall: 0.8955 - val_loss: 0.1652 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 91/150
0.9385 - recall: 0.9233 - val_loss: 0.1742 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 92/150
0.9503 - recall: 0.9120 - val_loss: 0.1634 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 93/150
0.9309 - recall: 0.8713 - val loss: 0.1651 - val accuracy: 0.9323 - val recall:
0.8939
Epoch 94/150
0.9523 - recall: 0.9146 - val_loss: 0.1631 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 95/150
0.9349 - recall: 0.8969 - val_loss: 0.1641 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 96/150
0.9380 - recall: 0.9029 - val_loss: 0.1697 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 97/150
0.9489 - recall: 0.9086 - val_loss: 0.1644 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 98/150
0.9416 - recall: 0.8976 - val_loss: 0.1622 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 99/150
0.9377 - recall: 0.9032 - val loss: 0.1811 - val accuracy: 0.9398 - val recall:
0.8788
Epoch 100/150
0.9335 - recall: 0.8685 - val_loss: 0.1627 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 101/150
0.9432 - recall: 0.8975 - val_loss: 0.1621 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 102/150
0.9568 - recall: 0.9160 - val_loss: 0.1729 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 103/150
0.9378 - recall: 0.9203 - val_loss: 0.1620 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 104/150
0.9465 - recall: 0.9155 - val_loss: 0.1610 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 105/150
0.9525 - recall: 0.9186 - val loss: 0.1625 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 106/150
0.9552 - recall: 0.9137 - val_loss: 0.1819 - val_accuracy: 0.9323 - val_recall:
0.9394
Epoch 107/150
0.9473 - recall: 0.9155 - val_loss: 0.1624 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 108/150
0.9505 - recall: 0.9172 - val_loss: 0.1605 - val_accuracy: 0.9398 - val_recall:
0.8939
```

```
Epoch 109/150
0.9478 - recall: 0.9106 - val_loss: 0.1697 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 110/150
0.9410 - recall: 0.9279 - val_loss: 0.1936 - val_accuracy: 0.9398 - val_recall:
0.8788
Epoch 111/150
0.9184 - recall: 0.8561 - val loss: 0.1737 - val accuracy: 0.9398 - val recall:
0.8788
Epoch 112/150
0.9301 - recall: 0.8855 - val_loss: 0.1716 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 113/150
0.9352 - recall: 0.8845 - val_loss: 0.1623 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 114/150
0.9410 - recall: 0.8866 - val_loss: 0.1694 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 115/150
0.9437 - recall: 0.9113 - val_loss: 0.1598 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 116/150
0.9455 - recall: 0.9134 - val_loss: 0.1593 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 117/150
0.9602 - recall: 0.9293 - val loss: 0.1715 - val accuracy: 0.9474 - val recall:
0.9242
Epoch 118/150
0.9411 - recall: 0.9016 - val_loss: 0.1609 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 119/150
0.9460 - recall: 0.9065 - val_loss: 0.1658 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 120/150
0.9536 - recall: 0.9180 - val_loss: 0.1610 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 121/150
0.9435 - recall: 0.8954 - val_loss: 0.1588 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 122/150
0.9368 - recall: 0.8981 - val_loss: 0.1586 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 123/150
0.9520 - recall: 0.9194 - val loss: 0.1763 - val accuracy: 0.9323 - val recall:
0.9394
Epoch 124/150
0.9380 - recall: 0.9214 - val_loss: 0.1581 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 125/150
0.9425 - recall: 0.9156 - val_loss: 0.1600 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 126/150
0.9473 - recall: 0.9234 - val_loss: 0.1810 - val_accuracy: 0.9398 - val_recall:
0.8788
Epoch 127/150
0.9414 - recall: 0.8844 - val_loss: 0.1606 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 128/150
0.9280 - recall: 0.8888 - val_loss: 0.1582 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 129/150
0.9568 - recall: 0.9315 - val loss: 0.1586 - val accuracy: 0.9398 - val recall:
0.8939
Epoch 130/150
0.9427 - recall: 0.9070 - val_loss: 0.1576 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 131/150
0.9562 - recall: 0.9204 - val_loss: 0.1612 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 132/150
0.9534 - recall: 0.9482 - val_loss: 0.1576 - val_accuracy: 0.9398 - val_recall:
0.8939
```

```
Epoch 133/150
0.9530 - recall: 0.9326 - val_loss: 0.1628 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 134/150
0.9389 - recall: 0.8959 - val_loss: 0.1630 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 135/150
0.9347 - recall: 0.8945 - val loss: 0.1638 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 136/150
0.9430 - recall: 0.8913 - val_loss: 0.1711 - val_accuracy: 0.9323 - val_recall:
0.9242
Epoch 137/150
0.9572 - recall: 0.9333 - val_loss: 0.1569 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 138/150
0.9486 - recall: 0.9191 - val_loss: 0.1567 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 139/150
0.9508 - recall: 0.9330 - val_loss: 0.1566 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 140/150
0.9476 - recall: 0.9139 - val_loss: 0.1668 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 141/150
0.9508 - recall: 0.9425 - val loss: 0.1695 - val accuracy: 0.9398 - val recall:
0.8788
Epoch 142/150
0.9477 - recall: 0.9046 - val_loss: 0.1594 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 143/150
0.9492 - recall: 0.9077 - val_loss: 0.1738 - val_accuracy: 0.9323 - val_recall:
0.9394
Epoch 144/150
0.9520 - recall: 0.9404 - val_loss: 0.1621 - val_accuracy: 0.9398 - val_recall:
0.8788
```

```
Epoch 145/150
    0.9501 - recall: 0.9042 - val_loss: 0.1571 - val_accuracy: 0.9398 - val_recall:
    0.8939
    Epoch 146/150
    0.9479 - recall: 0.9046 - val_loss: 0.1562 - val_accuracy: 0.9323 - val_recall:
    0.8939
    Epoch 147/150
    0.9267 - recall: 0.8899 - val loss: 0.1578 - val accuracy: 0.9398 - val recall:
    0.8939
    Epoch 148/150
    0.9511 - recall: 0.9135 - val_loss: 0.1549 - val_accuracy: 0.9398 - val_recall:
    0.8939
    Epoch 149/150
    0.9447 - recall: 0.9168 - val_loss: 0.1568 - val_accuracy: 0.9398 - val_recall:
    0.8939
    Epoch 150/150
    0.9392 - recall: 0.9052 - val_loss: 0.1613 - val_accuracy: 0.9398 - val_recall:
    0.8788
[229]: #a continuacion extraemos el indice de mayor rendimiento para obtener el epoch
    n_epochs=np.argmax(history.history["val_recall"])+1
    print("El numero de epochs adecuado es ",n_epochs)
    El numero de epochs adecuado es 75
[230]: model_unsampling=tuning.hypermodel.build(best_hps) #reconstruimos el modelo
    tensorboard_callback=tf.keras.callbacks.TensorBoard(log_dir="./graph/
     →deteccion_fraude/best_model_unsampling_last/")
    history=model unsampling.
     →fit(x_train,y_train,epochs=n_epochs,batch_size=BATCH_SIZE,validation_data=(x_val,y_val),cal
    0.7277 - recall: 0.6944 - val_loss: 0.6042 - val_accuracy: 0.8271 - val_recall:
    0.6515
    Epoch 2/75
    0.7933 - recall: 0.5448 - val_loss: 0.5598 - val_accuracy: 0.9098 - val_recall:
    0.8333
    Epoch 3/75
    0.8993 - recall: 0.8024 - val_loss: 0.5082 - val_accuracy: 0.8421 - val_recall:
    0.6818
```

```
Epoch 4/75
0.8339 - recall: 0.6646 - val loss: 0.4642 - val accuracy: 0.8797 - val recall:
0.7576
Epoch 5/75
0.8680 - recall: 0.7219 - val_loss: 0.4282 - val_accuracy: 0.9023 - val_recall:
0.8030
Epoch 6/75
0.8876 - recall: 0.7703 - val loss: 0.3921 - val accuracy: 0.8797 - val recall:
0.7576
Epoch 7/75
0.9003 - recall: 0.7976 - val_loss: 0.3717 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 8/75
0.8859 - recall: 0.7763 - val_loss: 0.3451 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 9/75
0.9054 - recall: 0.8060 - val_loss: 0.3217 - val_accuracy: 0.9023 - val_recall:
0.8030
Epoch 10/75
0.8893 - recall: 0.7688 - val_loss: 0.3091 - val_accuracy: 0.9023 - val_recall:
0.8182
Epoch 11/75
0.9026 - recall: 0.7969 - val_loss: 0.2977 - val_accuracy: 0.9098 - val_recall:
0.8333
Epoch 12/75
0.9037 - recall: 0.8119 - val loss: 0.2876 - val accuracy: 0.8947 - val recall:
0.7879
Epoch 13/75
0.8978 - recall: 0.7931 - val_loss: 0.2788 - val_accuracy: 0.8947 - val_recall:
0.7879
Epoch 14/75
0.8964 - recall: 0.7978 - val_loss: 0.2621 - val_accuracy: 0.9098 - val_recall:
0.8182
Epoch 15/75
0.9027 - recall: 0.8047 - val_loss: 0.2703 - val_accuracy: 0.9323 - val_recall:
0.8788
```

```
Epoch 16/75
0.9266 - recall: 0.8580 - val_loss: 0.2581 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 17/75
0.9253 - recall: 0.8813 - val_loss: 0.2483 - val_accuracy: 0.9023 - val_recall:
0.8030
Epoch 18/75
0.9122 - recall: 0.8328 - val loss: 0.2423 - val accuracy: 0.9023 - val recall:
0.8030
Epoch 19/75
0.8915 - recall: 0.7886 - val_loss: 0.2350 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 20/75
0.9227 - recall: 0.8558 - val_loss: 0.2293 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 21/75
0.9283 - recall: 0.8628 - val_loss: 0.2298 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 22/75
0.9304 - recall: 0.8714 - val_loss: 0.2274 - val_accuracy: 0.9173 - val_recall:
0.8333
Epoch 23/75
0.9178 - recall: 0.8402 - val_loss: 0.2177 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 24/75
0.9243 - recall: 0.8563 - val loss: 0.2156 - val accuracy: 0.9248 - val recall:
0.8636
Epoch 25/75
0.9237 - recall: 0.8647 - val_loss: 0.2256 - val_accuracy: 0.9023 - val_recall:
0.8030
Epoch 26/75
0.9187 - recall: 0.8366 - val_loss: 0.2159 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 27/75
0.9290 - recall: 0.8909 - val_loss: 0.2064 - val_accuracy: 0.9248 - val_recall:
0.8636
```

```
Epoch 28/75
0.9442 - recall: 0.8930 - val_loss: 0.2158 - val_accuracy: 0.9248 - val_recall:
0.8788
Epoch 29/75
0.9351 - recall: 0.8877 - val_loss: 0.2027 - val_accuracy: 0.9248 - val_recall:
0.8636
Epoch 30/75
0.9189 - recall: 0.8540 - val loss: 0.1996 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 31/75
0.9455 - recall: 0.8908 - val_loss: 0.1980 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 32/75
0.9249 - recall: 0.8712 - val_loss: 0.2029 - val_accuracy: 0.9323 - val_recall:
0.8636
Epoch 33/75
0.9283 - recall: 0.8527 - val_loss: 0.1980 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 34/75
0.9363 - recall: 0.8763 - val_loss: 0.1928 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 35/75
0.9419 - recall: 0.8866 - val_loss: 0.2062 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 36/75
0.9442 - recall: 0.9082 - val loss: 0.1912 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 37/75
0.9355 - recall: 0.8704 - val_loss: 0.1881 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 38/75
0.9176 - recall: 0.8515 - val_loss: 0.1930 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 39/75
0.9165 - recall: 0.8460 - val_loss: 0.1986 - val_accuracy: 0.9323 - val_recall:
0.8636
```

```
Epoch 40/75
0.9249 - recall: 0.8646 - val loss: 0.2010 - val accuracy: 0.9398 - val recall:
0.9091
Epoch 41/75
0.9272 - recall: 0.8782 - val_loss: 0.1892 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 42/75
0.9404 - recall: 0.8916 - val loss: 0.1833 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 43/75
0.9397 - recall: 0.8875 - val_loss: 0.1900 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 44/75
0.9441 - recall: 0.9108 - val_loss: 0.1815 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 45/75
0.9762 - recall: 0.941 - 0s 5ms/step - loss: 0.1640 - accuracy: 0.9505 - recall:
0.9009 - val_loss: 0.2168 - val_accuracy: 0.9173 - val_recall: 0.9242
Epoch 46/75
0.9226 - recall: 0.9050 - val_loss: 0.1800 - val_accuracy: 0.9323 - val_recall:
0.8788
0.9458 - recall: 0.9118 - val_loss: 0.1818 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 48/75
0.9314 - recall: 0.8860 - val loss: 0.1798 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 49/75
0.9373 - recall: 0.9045 - val_loss: 0.1778 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 50/75
0.9476 - recall: 0.9075 - val_loss: 0.1796 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 51/75
0.9318 - recall: 0.8767 - val_loss: 0.1811 - val_accuracy: 0.9323 - val_recall:
0.8788
```

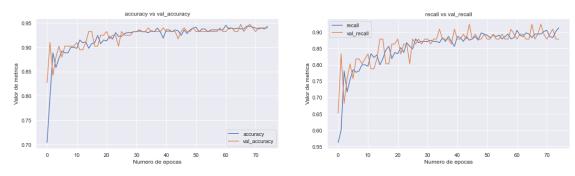
```
Epoch 52/75
0.9319 - recall: 0.8720 - val_loss: 0.1763 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 53/75
0.9332 - recall: 0.8822 - val_loss: 0.1796 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 54/75
0.9323 - recall: 0.8906 - val loss: 0.1774 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 55/75
0.9399 - recall: 0.8893 - val_loss: 0.1747 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 56/75
0.9406 - recall: 0.8867 - val_loss: 0.1782 - val_accuracy: 0.9323 - val_recall:
0.8939
Epoch 57/75
0.9279 - recall: 0.8845 - val_loss: 0.1771 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 58/75
0.9330 - recall: 0.8801 - val_loss: 0.1766 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 59/75
0.9387 - recall: 0.8826 - val_loss: 0.1860 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 60/75
0.9442 - recall: 0.9032 - val loss: 0.1790 - val accuracy: 0.9323 - val recall:
0.8939
Epoch 61/75
0.9458 - recall: 0.9118 - val_loss: 0.1728 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 62/75
0.9518 - recall: 0.9087 - val_loss: 0.1725 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 63/75
0.9412 - recall: 0.8859 - val_loss: 0.1717 - val_accuracy: 0.9398 - val_recall:
0.8939
```

```
Epoch 64/75
0.9374 - recall: 0.9014 - val loss: 0.1774 - val accuracy: 0.9323 - val recall:
0.8788
Epoch 65/75
0.9306 - recall: 0.8726 - val_loss: 0.1711 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 66/75
0.9393 - recall: 0.8932 - val loss: 0.1845 - val accuracy: 0.9474 - val recall:
0.9242
Epoch 67/75
0.9366 - recall: 0.9084 - val_loss: 0.1704 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 68/75
0.9432 - recall: 0.8943 - val_loss: 0.1703 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 69/75
0.9498 - recall: 0.9017 - val_loss: 0.1812 - val_accuracy: 0.9474 - val_recall:
0.9242
Epoch 70/75
0.9462 - recall: 0.9225 - val_loss: 0.1689 - val_accuracy: 0.9398 - val_recall:
0.8939
Epoch 71/75
0.9341 - recall: 0.8931 - val_loss: 0.1740 - val_accuracy: 0.9323 - val_recall:
0.8788
Epoch 72/75
0.9349 - recall: 0.8820 - val loss: 0.1707 - val accuracy: 0.9398 - val recall:
0.8939
Epoch 73/75
0.9513 - recall: 0.9081 - val_loss: 0.1788 - val_accuracy: 0.9398 - val_recall:
0.9091
Epoch 74/75
0.9423 - recall: 0.9191 - val_loss: 0.1864 - val_accuracy: 0.9398 - val_recall:
0.8788
Epoch 75/75
0.9319 - recall: 0.8731 - val_loss: 0.1823 - val_accuracy: 0.9398 - val_recall:
0.8788
```

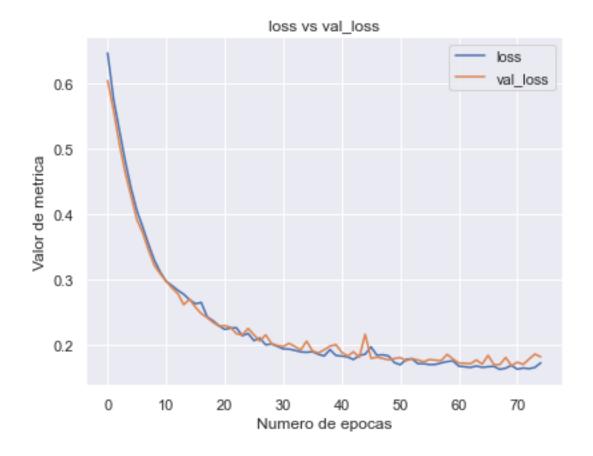
Exploremos los resultados del modelo graficamente

[234]: fig,(ax1,ax2)=plt.subplots(1,2,figsize=(20,5))

plot\_metrics(history.history,metrics=["accuracy","val\_accuracy"],ax=ax1)
plot\_metrics(history.history,metrics=["recall","val\_recall"],ax=ax2)



# [244]: plot\_metrics(history.history,metrics=["loss","val\_loss"])



## VALIDACION DEL MODELO: MODELO SUBMUESTREADO

[235]: model\_unsampling.evaluate(x\_val,y\_val)

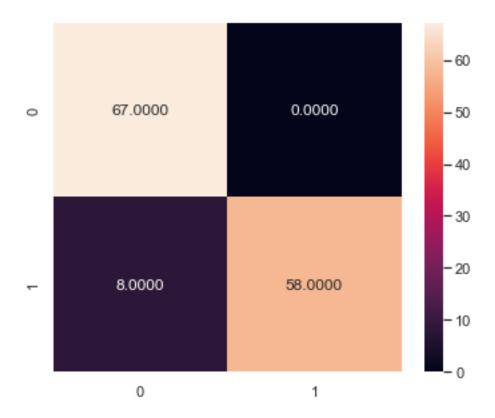
[235]: [0.1822652816772461, 0.9398496150970459, 0.8787878751754761]

Se obtuvo una puntuacion mas alta que del modelo base y modelo base V2,con un accuracy 93.98% que se solventa con un recall de 87.88% sobre los datos de validacion

[236]: display\_report\_and\_matrix\_confusion(model\_unsampling,x\_val,y\_val)

REPORTE I	DE CL	ASIFICACION			
		precision	recall	f1-score	support
	0.0	0.89	1.00	0.94	67
	1.0	1.00	0.88	0.94	66
accui	racy			0.94	133
macro	avg	0.95	0.94	0.94	133
weighted	avg	0.95	0.94	0.94	133

Matriz de confusion



Con esta matriz de confusion podemos determinar que el **submuestreo V3** es mucho mejor que los modelos base y modelo baseV2.

• Los falsos negativos se reducen a 8 unidades, y los falsos positivos a 0. Nosotros buscamos anular los falsos negativos lo mas posible

#### EVALUACION DEL MODELO CON SUBMUESTREO V3

• El conjunto de validación nos sirve para detener el entrenamiento cuando los resultados son buenos, ahora tendremos que probarlos con el conjunto de pruebas

[239]: [0.18961967527866364, 0.9295774698257446, 0.8732394576072693]

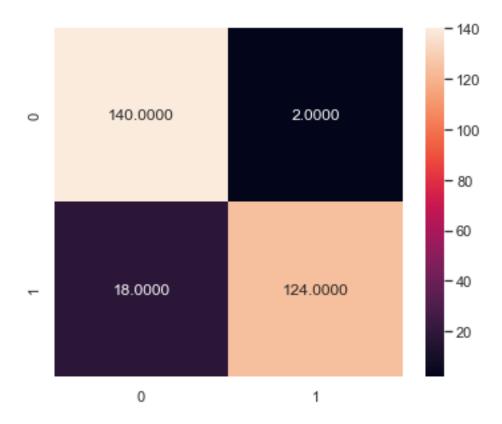
De hecho estos son resultados muy favorables ya que tenemos un accuracy 92.9% y un recall de 87.3% wow estos son resultados muy buenos, y mas si lo que buscabamos era un buen rendimiento con la metrica Recall

• Ahora veamos la matriz de confusion, nuestro objetivo aqui es ver si los falsos negativos han reducido

```
[240]: display_report_and_matrix_confusion(model_unsampling,x_test,y_test)
```

REPORTE DE C	LASIFICACION precision	recall	f1-score	support
0.0		0.99 0.87	0.93 0.93	142 142
accuracy macro avg weighted avg	0.94	0.93 0.93	0.93 0.93 0.93	284 284 284

Matriz de confusion



Como el modelo tiene un buen rendimiento optare por guardar el modelo con el formato **Saved-Model** para futuras integraciones

```
[241]: tf.saved_model.save(model_unsampling,"./best_endpoints/model_unsampling")

INFO:tensorflow:Assets written to: ./best_endpoints/model_unsampling\assets

[243]: #guardamos el metodo escalador
import joblib
joblib.dump(scaler_usmp,"./best_endpoints/scaler_unsampling.pkl")
```

[243]: ['./best\_endpoints/scaler\_unsampling.pkl']

#### 0.2.5 CONCLUSIONES PARCIALES DE LOS RESULTADOS

Tener en cuenta que se tomo como criterio principal aquel que posee un mayor numero de **recall** porque el caso de las transacciones son muy criticas

- El mejor modelo fue el de datos sobremuestreados con un puntaje de 99% de accuracy y 99% de recall sobre datos nunca vistos.
- 2do mejor modelo fue el de datos submuestreados con 92% de accuracy y 87% de recall

## PRUEBA FINAL. EVALUACION EN TODOS LOS DATOS -> No Necesaria

```
[20]: from sklearn.metrics import
       →accuracy_score,recall_score,precision_score,f1_score,confusion_matrix
      import numpy as np
      import pandas as pd
      import seaborn as sns
      import matplotlib.pyplot as plt
      import joblib
      import tensorflow as tf
      def test_best_models(X,y,list_components=None):
          score_models={
              "accuracy":[], "recall":[], "precision":[], "f1":[]
          }
          list_matrix=[]
          for path_scaler,path_model in_
       →zip(list_components["scalers"],list_components["models"]):
              scaler=joblib.load(path_scaler,mmap_mode="r")
              model=tf.keras.models.load_model(path_model)
              x_scaled=scaler.transform(X)
              y_pred=model.predict(x_scaled)
              y_pred=np.where(y_pred>=0.5,1,0)
              score_models["accuracy"].append(accuracy_score(y,y_pred))
              score_models["recall"].append(recall_score(y,y_pred))
              score_models["precision"].append(precision_score(y,y_pred))
              score_models["f1"].append(f1_score(y,y_pred))
              mat=confusion_matrix(y,y_pred)
              list_matrix.append(mat)
          report=pd.DataFrame(score_models,index=list_components["names"])
          return report,list_matrix
```

La funcion que preparamos espera un diccionario que posea las rutas de los modelos y los objetos escalers que se usaron sobre los datos

```
[16]: list_components={
    "names":["Base Model","Modelo sobremuestreado","Base Model
    →Mejorado","Modelo Submuestreado"],
```

Mostramos las comparativas

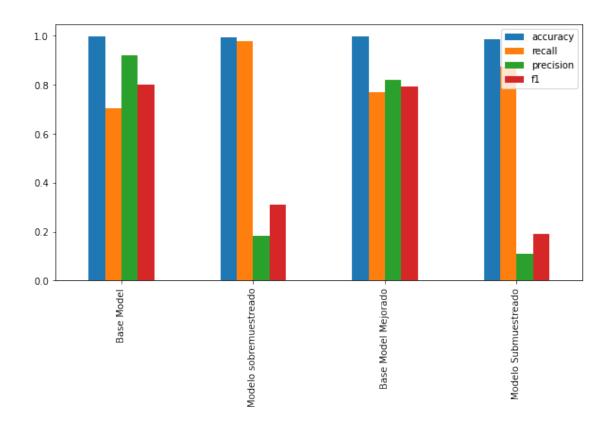
```
[21]: report, list_matrix=test_best_models(X,y,list_components)
```

```
[22]: report
```

```
[22]:
                             accuracy
                                        recall precision
                                                                 f1
     Base Model
                             0.999408 0.706131
                                                 0.920110 0.799043
     Modelo sobremuestreado 0.992708 0.978858
                                                 0.183584
                                                           0.309182
     Base Model Mejorado
                             0.999334 0.771670
                                                 0.818386
                                                           0.794342
     Modelo Submuestreado
                             0.987773 0.873150
                                                 0.108059 0.192317
```

```
[26]: report.plot(kind="bar",figsize=(10,5))
```

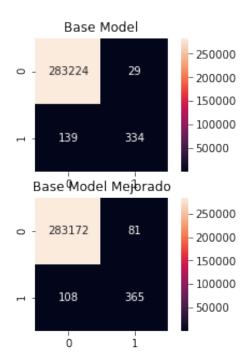
## [26]: <AxesSubplot:>

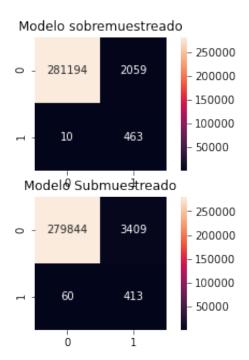


A primera vista es normal pensar que el modelo sobremuestreado no es mejor que el modelo base y otros, pero la verdad es que no es asi, debemos fijarnos mas en los objetivos del modelo y los datos predecidos

- Objetivos iniciales
- Evitar las transacciones fraudulentas
- Construir un modelo sensible al fraude donde sea preferible clasificar una transaccion normal como sospechosa que dejarla ir y al final sea un fraude que traera costos economicos a la entidad financiera.
- Las transacciones frudulentas deben ser lo mas minimo posible

Ahora veamos los resultados a traves de la matriz de confusion





Breve explicacion de las metricas bajas:

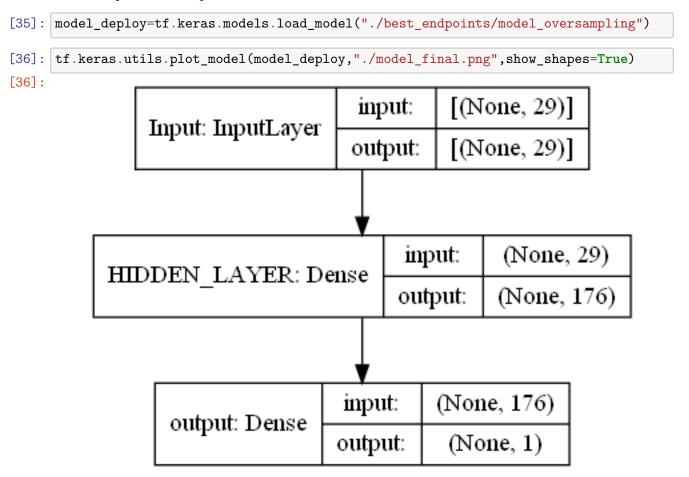
- **Precision**: Mide intuitivamente la capacidad de no clasificar como positivo una clase que es negativa [tp / (tp + fp)]. Por ello la metrica de precision observada en el modelo sobremuestreado es muy baja, por que ha obtenido muchos falsos positivos siendo el modelo sensible a las transacciones fraudulentas
- f1: Combina intuitivamente las metricas Recall y Precision

#### 0.2.6 CONCLUSIONES FINALES

- De hecho se suele pensar que el modelo con mas **accuracy** es el mejor, pero este no siempre es asi. En problemas de ciencia de datos donde es mejor obtener mas falsos positivos que falsos negativos como es el deteccion de fraude bancario, debemos tener en cuenta todas las metricas, y en este caso el **recall** debido a que si nos fijamos muy bien, el **modelo con datos sobremuestreados** ha sido el modelo que mas **recall** ha tenido y dejo pasar menos transacciones fraudulentas.
- El modelo sobremuestreado solo tiene 10 Falsos negativos que el resto de modelos. Esto a coste de que sea mas sensible al fraude y tenga mas Falsos positivos.
- En la vida real tener muchos falsos negativos, que son en este caso transacciones fraudulentas que no identificamos bien, equivalen a millones de soles de perdida de una entidad financiera y mas aun cuando los clientes estan asegurados.
- Los falsos positivos son aquellas transacciones normales que a menudo el modelo reconoce como fraudulenta, y es mejor asi, debido a que nos conviene enviar una confirmacion de la actividad bancaria del cliente por si hay sospechas de la transaccion, a dejarla pasar corriendo

el riesgo de que si sea fraudulenta. Esto se llama Costo del Falso Positivo por Falsos Negativos

El mejor modelo es el que uso sobremuestreo para obtener un conjunto de datos mas equilibrado, este es el que debe ir a produccion.



<pre>model_deploy.summary()</pre>					
Model: "sequential"					
Layer (type)	Output Shape	Param #			
HIDDEN_LAYER (Dense)	(None, 176)	5280			
output (Dense)	(None, 1)	177			
Total params: 5,457					
Trainable params: 5,457					
Non-trainable params: 0					

El modelo se puede implementar con **Tensorlow Serving o ML Flow** para asegurar su escalamiento, e inclusive se pueden hacer pruebas de test usando **Flask**.

 $\mathbf{Autor}$ \* Johan valerio Mitma Huaccha, 20 años \* Estudiante de Ing. sistemas en la UNMSM

Dedicado a mi madre Isabel Huaccha

Gracias

[39]: %load\_ext tensorboard %tensorboard --logdir="./graph/fraud\_detection/" #visualizacion interactiva de⊔ →las graficas de los modelos

Reusing TensorBoard on port 6006 (pid 32204), started 1:44:14 ago. (Use '!kill $_{\sqcup}$   $\rightarrow$ 32204' to kill it.)

<IPython.core.display.HTML object>

[]: